

Proyecto Final DBA

Daniel González, Eduardo De Brigard, Juan Pablo Hernández

10 de mayo de 2026

1. Introducción

En el marco de la transición energética impulsada por la Unidad de Planeación Minero Energética (UPME), surge la necesidad de identificar zonas estratégicas para el despliegue de infraestructura de energía renovable en Colombia. Este proyecto se enfoca específicamente en evaluar el potencial de generación solar en los techos de edificaciones dentro de los territorios priorizados por los Programas de Desarrollo con Enfoque Territorial (PDET), buscando promover la equidad territorial y el desarrollo en regiones históricamente vulnerables. El principal desafío técnico radica en el procesamiento masivo de datos. Para estimar el área disponible para paneles solares, es necesario integrar y comparar datasets globales que contienen miles de millones de registros de huellas de edificios (como Google Open Buildings y Microsoft Building Footprints), junto con la delimitación administrativa del DANE. Dada la escala de la información y la naturaleza geográfica de los datos, este documento presenta una propuesta basada en tecnologías NoSQL, específicamente utilizando MongoDB. El uso de este paradigma permite una gestión flexible de esquemas y, sobre todo, una ejecución eficiente de operaciones espaciales complejas, fundamentales para cruzar los límites municipales con las estructuras detectadas por satélite.

2. Diseño del esquema de base de datos NoSQL y plan de implementación

2.1. Plan de Implementación

1. Preparación de la Infraestructura NoSQL

- Despliegue de MongoDB: Configuración de una instancia de base de datos orientada a documentos para el almacenamiento masivo de datos vectoriales.
- Indexación Espacial: Implementación de índices de tipo `2dsphere` para optimizar las consultas de proximidad y contención geográfica.

2. Adquisición e Integración de Datos Territoriales

- Filtro PDET: Procesamiento del Marco Geoestadístico Nacional (MGN) del DANE para extraer y limpiar los límites de los municipios priorizados como territorios PDET.
- Ingesta de Huellas de Edificios: Carga y normalización de al menos dos de los datasets globales (Microsoft Building Footprints y Google Open Buildings) en la base de datos NoSQL.
- Verificación de Integridad: Validación de formatos estructurales, topología de geometrías y consistencia de códigos DIVIPOLA para asegurar la integridad referencial y la precisión espacial de los datos territoriales integrados en el esquema NoSQL.

3. Procesamiento y Análisis Geoespacial

- Intersección Espacial: Ejecución de operaciones de filtrado para identificar exclusivamente las estructuras ubicadas dentro de los polígonos municipales PDET.
- Cálculo de Áreas: Estimación de la superficie de los techos y conteo total de edificaciones por cada jurisdicción seleccionada.

4. Evaluación y Comparativa de Fuentes

- Auditoría de Datos (EDA): Realización de un análisis exploratorio para comparar la precisión y el volumen de detecciones entre los datasets seleccionados.
- Análisis de Discrepancias: Definición de métricas de validación para identificar variaciones en la detección de estructuras y determinar la fuente con mayor confiabilidad para el cálculo de áreas solares en los municipios seleccionados.

5. Consolidación de Resultados

- Generación de Reportes: Creación de visualizaciones cartográficas y tablas de resumen que identifiquen los municipios con mayor potencial para granjas solares.
- Documentación de Recomendaciones: Redacción de hallazgos técnicos alineados con los objetivos de transición energética y equidad territorial de la UPME.

3. Integración de Datos Territoriales y Filtro PDET

En continuidad con el plan de implementación, se llevó a cabo la integración de la información geoespacial base para disponer de una colección preparada para análisis e ingesta en el entorno NoSQL.

3.1. Metodología de procesamiento y normalización

Para seleccionar los territorios priorizados se automatizó el cruce entre el Marco Geoestadístico Nacional (MGN) 2025 del DANE y el listado oficial de municipios PDET mediante scripts reproducibles en Python utilizando GeoPandas, Pandas y Matplotlib.

El flujo implementado permitió garantizar consistencia territorial, normalización de atributos y preparación geoespacial para posteriores procesos de ingesta en MongoDB.

Las acciones principales realizadas durante el procesamiento fueron:

- Estandarización de códigos DIVIPOLA.
- Limpieza de nombres territoriales.
- Eliminación de caracteres Unicode y tildes.
- Validación de coincidencias territoriales.
- Conversión geoespacial a formato GeoJSON.

Como insumo principal del proceso se utilizó la capa administrativa nacional correspondiente al archivo:

`MGN_ADM_MPIO_GRAFICO.shp`




Figura 1: Visualización del shapefile administrativo MGN_ADM_MPIO_GRAFICO.shp cargado en QGIS. La capa representa la totalidad de municipios contenidos en el Marco Geoestadístico Nacional (MGN 2025) del DANE.

Posteriormente, el script en Python realizó el filtrado territorial correspondiente a municipios priorizados PDET y generó el archivo geoespacial:

pdet_final.geojson




Figura 2: Visualización programática del archivo pdet_final.geojson generado mediante Python y GeoPandas. Cada color representa municipios PDET filtrados tras el proceso de integración territorial.

Las visualizaciones obtenidas permitieron realizar un proceso preliminar de validación espacial, verificando continuidad topológica y consistencia geométrica respecto al shapefile original del DANE.

3.2. Validación geoespacial y control de calidad

Con el objetivo de validar la integridad geométrica del dataset resultante, se realizaron pruebas visuales mediante QGIS y validaciones programáticas utilizando Python.

Las validaciones efectuadas incluyeron:

- Superposición correcta entre el shapefile original y el GeoJSON generado.
- Validación por lotes de geometrías municipales.
- Validación individual de polígonos territoriales.
- Verificación de continuidad espacial.
- Detección de posibles desplazamientos o geometrías corruptas.

Superposición de capas territoriales

La superposición entre capas permitió verificar que la transformación espacial no introdujera inconsistencias territoriales ni pérdida de entidades durante la conversión.




Figura 3: Superposición entre el shapefile original del DANE y el archivo `pdet_final.geojson`. La comparación permitió validar continuidad topológica y consistencia espacial entre ambas capas.

Validación visual mediante simbología

Adicionalmente, se realizaron pruebas manuales modificando simbologías y colores de capas dentro de QGIS con el fin de identificar posibles anomalías geométricas o desplazamientos espaciales.




Figura 4: Validación visual mediante modificación de simbología y colores en QGIS. Este procedimiento permitió identificar posibles inconsistencias geométricas y verificar independencia topológica entre polígonos municipales.

Validación por lotes

El proceso de control incluyó validaciones por lotes sobre múltiples geometrías municipales para verificar integridad estructural y correcta carga espacial.




Figura 5: Proceso de validación por lotes realizado sobre múltiples geometrías municipales. La validación confirmó una carga espacial exitosa y ausencia de errores topológicos críticos.

Validación individual de geometrías

También se realizaron inspecciones individuales sobre municipios específicos con el objetivo de corroborar la correcta representación cartográfica y creación adecuada de nuevas capas territoriales.




Figura 6: Validación individual de geometrías territoriales. La inspección permitió corroborar la correcta representación cartográfica de municipios específicos dentro del conjunto PDET.

Evidencia de ejecución del pipeline

Durante la ejecución del pipeline geoespacial se obtuvieron resultados de validación en consola similares a los siguientes:

Cruce por código DANE: encontrados 170 registros.

--- RESULTADOS ---

Municipios cargados del SHP: 1123

Municipios en tu lista PDET: 170

Municipios PDET encontrados tras el cruce: 170

[OK] Archivo 'pdet_final.geojson' creado correctamente.

Estos resultados evidencian la correcta integración territorial y la generación satisfactoria del dataset geoespacial requerido para etapas posteriores del proyecto.




Figura 7: Salida en consola del pipeline geoespacial implementado en Python, evidenciando la carga del shapefile, integración territorial y generación del archivo GeoJSON final.

Exportación geoespacial final

La exportación del subconjunto territorial resultante se realizó mediante la siguiente instrucción:

```
resultado_final.to_file(
    "pdet_final.geojson",
    driver="GeoJSON"
)
```

Esta transformación constituye una etapa crítica dentro del pipeline geoespacial, debido a que permite convertir estructuras territoriales tradicionales en objetos GeoJSON compatibles con MongoDB y operaciones espaciales NoSQL.

3.3. Modelo de Datos Inicial

Dado que el proyecto requiere una solución NoSQL, el modelado se centra en la estructura de documentos JSON (BSON) y en la optimización de consultas geoespaciales. A continuación, se definen las dos entidades principales y su interacción lógica:

3.3.1. A. Representación del Modelo (Estructura de Documentos)

Colección: territorios_pdet

- **_id**: Identificador único (ObjectId)
- **codigo_mgn**: Código municipal del DANE
- **nombre_municipio**: Nombre oficial
- **geometria_pdet**: Objeto GeoJSON (MultiPolygon) que define los límites del municipio
- **datos_pdet**: Información sobre el programa de desarrollo

Colección: huellas_edificios

- **_id**: Identificador único (ObjectId)
- **fuelle**: Origen del dato (Microsoft o Google)
- **geometria_edificio**: Objeto GeoJSON (Polygon) con la huella del edificio
- **area_estimada_m2**: Valor numérico calculado para el potencial solar
- **metadata**: Confianza de detección y fecha de captura




Figura 8: Esquema de base de datos

3.3.2. B. Instrumento de Modelado: Relación Espacial

En este modelo, la relación no se define mediante claves foráneas como en bases de datos relacionales, sino mediante una lógica de contención espacial:

- **Vínculo lógico**: Un documento en **huellas_edificios** pertenece a un territorio en **territorios_pdet** si su **geometria_edificio** está contenida dentro de **geometria_pdet**.
- **Mecanismo de consulta**: Se utilizará el operador **\$geoWithin** de MongoDB para realizar el cruce de datos en tiempo de ejecución, evitando redundancia innecesaria.

3.4. Esquema de Datos y Justificación

Para cumplir con el requerimiento de una solución escalable y eficiente en operaciones espaciales, se ha diseñado un esquema basado en dos colecciones principales dentro de MongoDB.

3.4.1. Descripción de las Colecciones

Colección: pdet_territories

- **Propósito:** Almacenar los límites administrativos de los municipios designados como PDET, derivados del Marco Geoestadístico Nacional (MGN) del DANE.
- **Contenido:** Documentos que contienen el código municipal, nombre oficial y un campo **geometry** de tipo MultiPolygon bajo el estándar GeoJSON.
- **Índice:** Se implementará un índice **2dsphere** sobre el campo de geometría para permitir consultas de contención rápidas.

Colección: building_footprints

- **Propósito:** Consolidar las detecciones de edificios de los datasets de Google Open Buildings y Microsoft Building Footprints para su comparación.
- **Contenido:** Documentos con la huella del edificio (**Polygon**), el área calculada, la fuente del dato y metadatos de confianza.
- **Optimización:** Se incluirá un campo con el código municipal (obtenido tras el procesamiento inicial) para facilitar agregaciones estadísticas sin necesidad de realizar cruces espaciales en cada consulta.

3.4.2. Justificación Técnica

La elección de este esquema y del motor NoSQL (MongoDB) se fundamenta en los siguientes pilares:

- **Soporte nativo geoespacial:** A diferencia de las bases de datos relacionales tradicionales, MongoDB maneja objetos GeoJSON de forma nativa. Esto facilita la ejecución de operadores como **\$geoWithin** y **\$geoIntersects**, esenciales para determinar qué edificios pertenecen a cada municipio PDET.
- **Escalabilidad:** El proyecto requiere procesar millones de registros provenientes de datasets globales de huellas de edificios. MongoDB permite manejar grandes volúmenes de información geoespacial de forma distribuida y eficiente.
- **Flexibilidad de esquema:** Debido a que los datasets utilizados provienen de múltiples fuentes (Google y Microsoft), existen diferencias estructurales y variaciones en atributos. El modelo orientado a documentos facilita la integración de estructuras heterogéneas sin requerir migraciones complejas.
- **Optimización de consultas espaciales:** La implementación de índices **2dsphere** permite acelerar operaciones de proximidad, intersección y contención espacial sobre polígonos territoriales y huellas de edificaciones.
- **Compatibilidad con pipelines geoespaciales:** El uso de GeoJSON facilita la interoperabilidad entre herramientas como QGIS, GeoPandas y MongoDB, permitiendo mantener consistencia espacial durante todas las etapas del procesamiento.

4. Conclusión

En el desarrollo de esta fase del proyecto se diseñó una arquitectura NoSQL orientada al procesamiento y análisis de información geoespacial asociada a territorios PDET y huellas de edificaciones. La solución propuesta utiliza MongoDB como motor principal debido a su soporte nativo para estructuras GeoJSON y consultas espaciales avanzadas.

Como resultado del proceso de integración territorial, se logró consolidar un conjunto geoespacial validado a partir del Marco Geoestadístico Nacional (MGN 2025) del DANE y del listado oficial de municipios PDET. El pipeline implementado permitió realizar procesos de limpieza, normalización, validación topológica y exportación a formatos compatibles con tecnologías NoSQL.

Adicionalmente, se definieron las colecciones principales del modelo de datos (`territorios_pdet` y `huellas_edificios`), así como la estrategia de indexación geoespacial mediante índices `2dsphere`, fundamentales para optimizar operaciones de intersección y contención espacial sobre grandes volúmenes de datos territoriales.

La transición desde formatos tradicionales como Shapefile hacia estructuras GeoJSON representa una mejora significativa en términos de interoperabilidad, escalabilidad y eficiencia computacional. Esto permitirá integrar posteriormente datasets masivos de edificaciones provenientes de Google Open Buildings y Microsoft Building Footprints para estimar áreas disponibles para infraestructura solar en municipios priorizados.

Finalmente, el trabajo desarrollado establece una base sólida para las siguientes etapas del proyecto, las cuales incluyen la ingesta masiva de huellas de edificios, la ejecución de consultas geoespaciales avanzadas y la generación de métricas territoriales orientadas al análisis del potencial solar y apoyo a estrategias de transición energética en Colombia.