

Proyecto Final

Diseño e Implementación de Arquitectura NoSQL Geoespacial para Análisis de Potencial Solar en Territorios PDET

Daniel González, Eduardo De Brigard, Juan Pablo Hernández

31 de mayo de 2026

1. Introducción

En el marco de la transición energética impulsada por la Unidad de Planeación Minero Energética (UPME), surge la necesidad de identificar zonas estratégicas para el despliegue de infraestructura de energía renovable en Colombia. Este proyecto se enfoca específicamente en evaluar el potencial de generación solar en los techos de edificaciones dentro de los territorios priorizados por los Programas de Desarrollo con Enfoque Territorial (PDET), buscando promover la equidad territorial y el desarrollo en regiones históricamente vulnerables. El principal desafío técnico radica en el procesamiento masivo de datos. Para estimar el área disponible para paneles solares, es necesario integrar y comparar datasets globales que contienen miles de millones de registros de huellas de edificios (como Google Open Buildings y Microsoft Building Footprints), junto con la delimitación administrativa del DANE. Dada la escala de la información y la naturaleza geográfica de los datos, este documento presenta una propuesta basada en tecnologías NoSQL, específicamente utilizando MongoDB. El uso de este paradigma permite una gestión flexible de esquemas y, sobre todo, una ejecución eficiente de operaciones espaciales complejas, fundamentales para cruzar los límites municipales con las estructuras detectadas por satélite.

2. Diseño del esquema de base de datos NoSQL y plan de implementación

2.1. Plan de Implementación

1. Preparación de la Infraestructura NoSQL

- Despliegue de MongoDB: Configuración de una instancia de base de datos orientada a documentos para el almacenamiento masivo de datos vectoriales.
- Indexación Espacial: Implementación de índices de tipo `2dsphere` para optimizar las consultas de proximidad y contención geográfica.

2. Adquisición e Integración de Datos Territoriales

- Filtro PDET: Procesamiento del Marco Geoestadístico Nacional (MGN) del DANE para extraer y limpiar los límites de los municipios priorizados como territorios PDET.
- Ingesta de Huellas de Edificios: Carga y normalización de al menos dos de los datasets globales (Microsoft Building Footprints y Google Open Buildings) en la base de datos NoSQL.
- Verificación de Integridad: Validación de formatos estructurales, topología de geometrías

y consistencia de códigos DIVIPOLA para asegurar la integridad referencial y la precisión espacial de los datos territoriales integrados en el esquema NoSQL.

3. Procesamiento y Análisis Geoespacial

- Intersección Espacial: Ejecución de operaciones de filtrado para identificar exclusivamente las estructuras ubicadas dentro de los polígonos municipales PDET.
- Cálculo de Áreas: Estimación de la superficie de los techos y conteo total de edificaciones por cada jurisdicción seleccionada.

4. Evaluación y Comparativa de Fuentes

- Auditoría de Datos (EDA): Realización de un análisis exploratorio para comparar la precisión y el volumen de detecciones entre los datasets seleccionados.
- Análisis de Discrepancias: Definición de métricas de validación para identificar variaciones en la detección de estructuras y determinar la fuente con mayor confiabilidad para el cálculo de áreas solares en los municipios seleccionados.

5. Consolidación de Resultados

- Generación de Reportes: Creación de visualizaciones cartográficas y tablas de resumen que identifiquen los municipios con mayor potencial para granjas solares.
- Documentación de Recomendaciones: Redacción de hallazgos técnicos alineados con los objetivos de transición energética y equidad territorial de la UPME.

2.2. Diseño del Modelo de Datos

2.2.1. A. Representación del Modelo (Estructura de Documentos)

A continuación, se presentan las colecciones principales definidas para el almacenamiento y procesamiento de información geoespacial dentro del entorno NoSQL propuesto.

Colección: territorios_pdet

- `_id`: Identificador único (ObjectId)
- `codigo_mgn`: Código municipal del DANE
- `nombre_municipio`: Nombre oficial
- `geometria_pdet`: Objeto GeoJSON (MultiPolygon) que define los límites del municipio
- `datos_pdet`: Información sobre el programa de desarrollo

Colección: huellas_edificios

- `_id`: Identificador único (ObjectId)
- `fuentes`: Origen del dato (Microsoft o Google)
- `geometria_edificio`: Objeto GeoJSON (Polygon) con la huella del edificio
- `area_estimada_m2`: Valor numérico calculado para el potencial solar
- `metadata`: Confianza de detección y fecha de captura




Figura 1: Esquema de base de datos

2.2.2. B. Instrumento de Modelado: Relación Espacial

En este modelo, la relación no se define mediante claves foráneas como en bases de datos relacionales, sino mediante una lógica de contención espacial:

- **Vínculo lógico:** Un documento en `huellas_edificios` pertenece a un territorio en `territorios_pdet` si su `geometria_edificio` está contenida dentro de `geometria_pdet`.
- **Mecanismo de consulta:** Se utilizará el operador `$geoWithin` de MongoDB para realizar el cruce de datos en tiempo de ejecución, evitando redundancia innecesaria.

2.3. Esquema de Datos y Justificación

Para cumplir con el requerimiento de una solución escalable y eficiente en operaciones espaciales, se ha diseñado un esquema basado en dos colecciones principales dentro de MongoDB.

2.3.1. Descripción de las Colecciones

Colección: `pdet_territories`

- **Propósito:** Almacenar los límites administrativos de los municipios designados como PDET, derivados del Marco Geoestadístico Nacional (MGN) del DANE.
- **Contenido:** Documentos que contienen el código municipal, nombre oficial y un campo `geometry` de tipo MultiPolygon bajo el estándar GeoJSON.
- **Índice:** Se implementará un índice `2dsphere` sobre el campo de geometría para permitir consultas de contención rápidas.

Colección: `building_footprints`

- **Propósito:** Consolidar las detecciones de edificios de los datasets de Google Open Buildings y Microsoft Building Footprints para su comparación.
- **Contenido:** Documentos con la huella del edificio (Polygon), el área calculada, la fuente del

dato y metadatos de confianza.

- **Optimización:** Se incluirá un campo con el código municipal (obtenido tras el procesamiento inicial) para facilitar agregaciones estadísticas sin necesidad de realizar cruces espaciales en cada consulta.

2.3.2. Justificación Técnica

La elección de este esquema y del motor NoSQL (MongoDB) se fundamenta en los siguientes pilares:

- **Soporte nativo geoespacial:** A diferencia de las bases de datos relacionales tradicionales, MongoDB maneja objetos GeoJSON de forma nativa. Esto facilita la ejecución de operadores como `$geoWithin` y `$geoIntersects`, esenciales para determinar qué edificios pertenecen a cada municipio PDET.
- **Escalabilidad:** El proyecto requiere procesar millones de registros provenientes de datasets globales de huellas de edificios. MongoDB permite manejar grandes volúmenes de información geoespacial de forma distribuida y eficiente.
- **Flexibilidad de esquema:** Debido a que los datasets utilizados provienen de múltiples fuentes (Google y Microsoft), existen diferencias estructurales y variaciones en atributos. El modelo orientado a documentos facilita la integración de estructuras heterogéneas sin requerir migraciones complejas.
- **Optimización de consultas espaciales:** La implementación de índices `2dsphere` permite acelerar operaciones de proximidad, intersección y contención espacial sobre polígonos territoriales y huellas de edificaciones.
- **Compatibilidad con pipelines geoespaciales:** El uso de GeoJSON facilita la interoperabilidad entre herramientas como QGIS, GeoPandas y MongoDB, permitiendo mantener consistencia espacial durante todas las etapas del procesamiento.

2.4. Integración de Datos Territoriales y Filtro PDET

En continuidad con el plan de implementación, se llevó a cabo la integración de la información geoespacial base para disponer de una colección preparada para análisis e ingesta en el entorno NoSQL.

2.4.1. Metodología de procesamiento y normalización

Para seleccionar los territorios priorizados se automatizó el cruce entre el Marco Geoestadístico Nacional (MGN) 2025 del DANE y el listado oficial de municipios PDET mediante scripts reproducibles en Python utilizando GeoPandas, Pandas y Matplotlib.

El flujo implementado permitió garantizar consistencia territorial, normalización de atributos y preparación geoespacial para posteriores procesos de ingesta en MongoDB.

Las acciones principales realizadas durante el procesamiento fueron:

- Estandarización de códigos DIVIPOLA.
- Limpieza de nombres territoriales.
- Eliminación de caracteres Unicode y tildes.
- Validación de coincidencias territoriales.
- Conversión geoespacial a formato GeoJSON.

Como insumo principal del proceso se utilizó la capa administrativa nacional correspondiente al archivo:

`MGN_ADM_MPIO_GRAFICO.shp`




Figura 2: Visualización del shapefile administrativo `MGN_ADM_MPIO_GRAFICO.shp` cargado en QGIS. La capa representa la totalidad de municipios contenidos en el Marco Geoestadístico Nacional (MGN 2025) del DANE.

Posteriormente, el script en Python realizó el filtrado territorial correspondiente a municipios priorizados PDET y generó el archivo geoespacial:

`pdet_final.geojson`

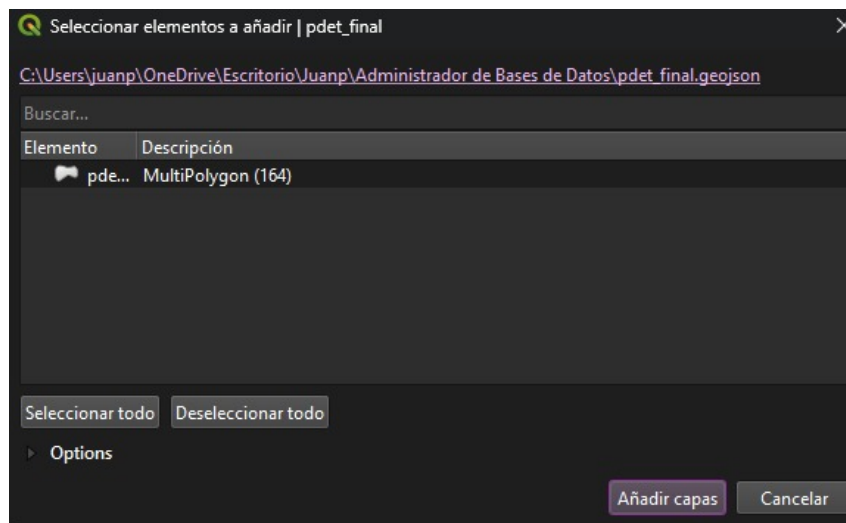


Figura 3: Visualización programática del archivo `pdet_final.geojson` generado mediante Python y GeoPandas. Cada color representa municipios PDET filtrados tras el proceso de integración territorial.

Las visualizaciones obtenidas permitieron realizar un proceso preliminar de validación espacial, verificando continuidad topológica y consistencia geométrica respecto al shapefile original del DANE.

2.4.2. Validación geoespacial y control de calidad

Con el objetivo de validar la integridad geométrica del dataset resultante, se realizaron pruebas visuales mediante QGIS y validaciones programáticas utilizando Python.

Las validaciones efectuadas incluyeron:

- Superposición correcta entre el shapefile original y el GeoJSON generado.
- Validación por lotes de geometrías municipales.
- Validación individual de polígonos territoriales.
- Verificación de continuidad espacial.
- Detección de posibles desplazamientos o geometrías corruptas.

Superposición de capas territoriales

La superposición entre capas permitió verificar que la transformación espacial no introdujera inconsistencias territoriales ni pérdida de entidades durante la conversión.




Figura 4: Superposición entre el shapefile original del DANE y el archivo `pdet_final.geojson`. La comparación permitió validar continuidad topológica y consistencia espacial entre ambas capas.

Validación visual mediante simbología

Adicionalmente, se realizaron pruebas manuales modificando simbologías y colores de capas dentro de QGIS con el fin de identificar posibles anomalías geométricas o desplazamientos espaciales.




Figura 5: Validación visual mediante modificación de simbología y colores en QGIS. Este procedimiento permitió identificar posibles inconsistencias geométricas y verificar independencia topológica entre polígonos municipales.

Validación por lotes

El proceso de control incluyó validaciones por lotes sobre múltiples geometrías municipales para verificar integridad estructural y correcta carga espacial.




Figura 6: Proceso de validación por lotes realizado sobre múltiples geometrías municipales. La validación confirmó una carga espacial exitosa y ausencia de errores topológicos críticos.

Validación individual de geometrías

También se realizaron inspecciones individuales sobre municipios específicos con el objetivo de corroborar la correcta representación cartográfica y creación adecuada de nuevas capas territoriales.




Figura 7: Validación individual de geometrías territoriales. La inspección permitió corroborar la correcta representación cartográfica de municipios específicos dentro del conjunto PDET.

Evidencia de ejecución del pipeline

Durante la ejecución del pipeline geoespacial se obtuvieron resultados de validación en consola similares a los siguientes:

Cruce por código DANE: encontrados 170 registros.

--- RESULTADOS ---

Municipios cargados del SHP: 1122

Municipios en tu lista PDET: 170

Municipios PDET encontrados tras el cruce: 170

[OK] Archivo 'pdet_final.geojson' creado correctamente.

Estos resultados evidencian la correcta integración territorial y la generación satisfactoria del dataset geoespacial requerido para etapas posteriores del proyecto.




Figura 8: Salida en consola del pipeline geoespacial implementado en Python, evidenciando la carga del shapefile, integración territorial y generación del archivo GeoJSON final.

Exportación geoespacial final

La exportación del subconjunto territorial resultante se realizó mediante la siguiente instrucción:

```
resultado_final.to_file(
    "pdet_final.geojson",
    driver="GeoJSON"
)
```

Esta transformación constituye una etapa crítica dentro del pipeline geoespacial, debido a que permite convertir estructuras territoriales tradicionales en objetos GeoJSON compatibles con MongoDB y operaciones espaciales NoSQL.

3. Adquisición de Datos

3.1. Google Open Buildings

3.1.1. Descripción del dataset

Google Open Buildings es un dataset desarrollado por Google Research que contiene detecciones de edificios derivadas de imágenes satelitales de alta resolución. La versión 3 del dataset cubre Lati-

noamérica, el Caribe, África, Asia del Sur y Asia del Sureste, con un área de inferencia de 58 millones de km².

Cuadro 1: Características del dataset Google Open Buildings

Atributo	Detalle
Versión	v3 (tercera versión)
Detecciones totales	~1.8 mil millones
Área de cobertura	58 millones de km ²
Formato de distribución	CSV comprimido (.csv.gz) por cuadrante
Atributos principales	geometry (WKT), area_in_meters, confidence, full_plus_code
Licencia	CC BY-4.0 / ODbL v1.0
URL	https://sites.research.google/gr/open-buildings/

3.1.2. Proceso de descarga

Los archivos fueron descargados directamente desde el portal de Google Open Buildings, filtrando por la región correspondiente a Colombia. Cada archivo CSV comprimido contiene las huellas de edificios para un cuadrante geográfico específico, con los siguientes campos principales:




Figura 9: Microsoft Building Footprints

Esto descarga unos archivos .csv.grz en los cuales estan los datos, en el script.py, se aplicó un filtro mínimo de confianza de **0.60** durante la carga, descartando detecciones con baja certeza de ser edificaciones reales.

3.2. Microsoft Global ML Building Footprints

3.2.1. Descripción del dataset

Microsoft Global ML Building Footprints es un dataset desarrollado por Microsoft Research a partir de imágenes de Bing Maps recolectadas entre 2014 y 2021, incorporando fuentes como Maxar y Airbus. Contiene más de 999 millones de detecciones de edificios a nivel mundial.

Cuadro 2: Características del dataset Microsoft Building Footprints

Atributo	Detalle
Detecciones totales	>999 millones
Período de imágenes	2014 – 2021
Formato de distribución	GeoJSON por cuadrante (QuadKey)
Atributos principales	geometry (GeoJSON Polygon), height, confidence
Licencia	Open Data Commons Open Database License (ODbL)
URL	https://planetarycomputer.microsoft.com/dataset/ms-buildings

3.2.2. Proceso de descarga

Microsoft distribuye sus datos a través de un índice CSV que lista todos los cuadrantes disponibles por país. El proceso de descarga se basó en el snippet oficial de Microsoft, adaptado para filtrar únicamente los cuadrantes correspondientes a Colombia, este proceso de descarga se puede ver en el pruebasDosMicro.py:

```

INDEX_URL = "https://mimedbuildings.z5.web.core.windows.net/global-buildings/dataset-links.csv"
LOCATION = "Colombia"
OUTPUT_FOLDER = "microsoft_geojson"

def main():
    log.info("=== Descarga Microsoft Buildings - Colombia ===")

    os.makedirs(OUTPUT_FOLDER, exist_ok=True)

    # — 1. Descargar índice oficial de Microsoft —————
    log.info("Descargando índice de cuadrantes...")
    dataset_links = pd.read_csv(INDEX_URL)
    colombia_links = dataset_links[dataset_links.Location == LOCATION].reset_index(drop=True)
    log.info(f"Cuadrantes de {LOCATION}: {len(colombia_links)}")

    # — 2. Descargar cada cuadrante —————
    ok = 0
    errores = 0

    for i, row in colombia_links.iterrows():
        quadkey = row.QuadKey
        url = row.Url
        destino = os.path.join(OUTPUT_FOLDER, f"{quadkey}.geojson")

        # Si ya existe, saltar
        if os.path.exists(destino):
            log.info(f" [{i+1}/{len(colombia_links)}] Ya existe: {quadkey}.geojson")
            ok += 1
            continue

        try:
            log.info(f" [{i+1}/{len(colombia_links)}] Descargando: {quadkey} ...")

            # Igual que el snippet oficial de Microsoft
            df = pd.read_json(url, lines=True)
            df["geometry"] = df["geometry"].apply(shape)
            gdf = gpd.GeoDataFrame(df, crs=4326)
            gdf.to_file(destino, driver="GeoJSON")

            log.info(f"    -> {len(gdf),} edificios guardados en {quadkey}.geojson")
            ok += 1

```

Figura 10: Google open buildings

Para Colombia se identificaron y descargaron **229 cuadrantes GeoJSON**, cada uno correspondiente a un QuadKey único del sistema de indexación de Bing Maps.

4. Integración en MongoDB e Indexación Espacial

4.1. Arquitectura de colecciones

Los datos fueron almacenados en tres colecciones dentro de la base de datos proyecto en MongoDB:

Cuadro 3: Colecciones en MongoDB

Colección	Documentos	Propósito
territorios_pdet	170	Límites municipales PDET
google_buildings	2,687,624	Huellas de edificios (Google)
microsoft_buildings	1,537,635	Huellas de edificios (Microsoft)

4.2. Esquema de documento

Cada edificio, independientemente de la fuente, sigue el esquema unificado definido desde la semana 1:

```

1 {
2   "_id":           ObjectId,
3   "fuente":        "google" | "microsoft",
4   "codigo_mgn":    "47001",           // código DANE del municipio
5   "nombre_municipio": "SANTA MARTA",
6   "geometria_edificio": {             // GeoJSON Polygon
7     "type": "Polygon",
8     "coordinates": [[[lng, lat], ...]]
9   },
10  "area_estimada_m2": 87.39,           // solo Google
11  "metadata": {
12    "confianza":      0.78,
13    "altura_m":       null,           // solo Microsoft cuando disponible
14    "fuente_imagen":  "Google Satellite Imagery",
15    "dataset_version": "Google Open Buildings v3"
16  }
17 }
```

Listing 1: Esquema unificado de documento en mongodb

4.3. Indexación espacial

Se implementaron índices `2dsphere` sobre el campo `geometria_edificio` en ambas colecciones de edificios, junto con índices auxiliares para acelerar consultas por fuente y municipio:

```

1 # Índice geoespacial 2dsphere (requerido para geoWithin, geoIntersects)
2 col.create_index(
3   [("geometria_edificio", GEOSPHERE)],
4   name="idx_geo_edificio"
5 )
6 # Índices auxiliares para agregaciones
7 col.create_index("fuente", name="idx_fuente")
8 col.create_index("codigo_mgn", name="idx_codigo_mgn")
```

Listing 2: Creación de índices espaciales en MongoDB

4.4. Proceso de cruce espacial y filtro PDET

Un paso crítico en el pipeline de carga fue el cruce espacial entre cada edificio y los polígonos PDET. Solo se insertaron en MongoDB los edificios cuyo centroide cayera *dentro* de algún municipio PDET. Este filtro se implementó de dos formas según la fuente:

- **Google:** lectura por lotes de archivos CSV, conversión de geometrías WKT a objetos Shapely, uso de **STRtree** para consulta espacial eficiente y validación mediante el centroide de cada huella contra los polígonos PDET.
- **Microsoft:** lectura de archivos GeoJSON por cuadrante, reparación y validación de geometrías poligonales, asignación municipal mediante el centroide de cada edificio y limpieza posterior de geometrías incompatibles con índices **2dsphere**.

Aunque MongoDB permite ejecutar consultas espaciales mediante operadores como **\$geoWithin** y **\$geoIntersects**, en el pipeline final se decidió almacenar el campo **codigo_mgn** directamente en cada edificio durante la carga. Esta decisión reduce el costo de las agregaciones posteriores, ya que evita repetir cruces espaciales sobre millones de geometrías en cada consulta.

4.5. Eficiencia de carga

Para garantizar una carga eficiente de grandes volúmenes de datos, se implementó escritura por lotes con un tamaño de lote de 20,000 documentos. Además, los índices espaciales fueron creados al final de la carga para evitar que MongoDB actualizara los índices durante cada inserción masiva.

```

1 BATCH_SIZE = 20_000
2
3 batch.append(doc)
4
5 if len(batch) >= BATCH_SIZE:
6     col.insert_many(batch, ordered=False)
7     batch = []
8
9 if batch:
10    col.insert_many(batch, ordered=False)

```

Listing 3: Inserción por lotes optimizada

El parámetro **ordered=False** permite que MongoDB procese las inserciones en paralelo, mejorando el rendimiento y tolerando errores individuales sin detener el proceso completo.

5. Auditoría Inicial de Datos (EDA)

5.1. Resumen general

Tras completar la carga de ambos datasets, se realizó un análisis exploratorio de datos (EDA) directamente sobre las colecciones de MongoDB mediante pipelines de agregación. Los resultados globales se presentan a continuación:

Cuadro 4: Resumen general de edificios cargados y consolidación final

Métrica	Valor
Municipios PDET cargados	170
Edificios Google cargados	2.687.624
Edificios Microsoft cargados después de limpieza geométrica	1.537.635
Total de huellas procesadas en ambas fuentes	4.225.259
Duplicados Microsoft-Google detectados	764.492
Edificios Microsoft únicos agregados	773.143
Total final de edificios sin duplicados	3.460.767
Área total de techos sin duplicados (m ²)	282.191.579,71
Área total de techos sin duplicados (ha)	28.219,16
Área total de techos sin duplicados (km ²)	282,19

Nota sobre Microsoft: el dataset de Microsoft no incluye el campo `area_in_meters` en sus GeoJSON de distribución. Los valores de `height` y `confidence` registrados en los archivos descargados para Colombia presentaron valores de -1, indicando que no estaban disponibles para esta región en particular.

Debido a la ausencia de un atributo de área directamente comparable en Microsoft, el área de techos para esta fuente fue calculada geométicamente a partir de las huellas proyectadas al sistema de referencia métrico EPSG:9377. Para mantener consistencia metodológica, el análisis final también calculó áreas geométricas sobre las huellas consolidadas.

5.2. Cobertura territorial comparativa

La cobertura territorial se evaluó sobre los **170 municipios PDET** cargados en la colección `territorios_pdet`. Para cada municipio se calcularon conteos separados por fuente y un resultado consolidado sin duplicados.

La estrategia final no consistió únicamente en sumar las detecciones de Google y Microsoft. En cambio, se compararon espacialmente las huellas de ambas fuentes para identificar posibles duplicados. Cuando una huella de Microsoft presentaba un solapamiento significativo con una huella de Google, se consideró duplicada y no se agregó al resultado final.

La regla de deduplicación utilizada fue:

$$\frac{\text{Área de intersección}}{\min(\text{Área Google}, \text{Área Microsoft})} \geq 0,50$$

Bajo esta regla, Google se conservó como fuente prioritaria y Microsoft se utilizó como fuente complementaria para agregar únicamente edificios no detectados por Google.

Cuadro 5: Consolidación entre fuentes después de deduplicación espacial

Categoría	Edificios
Google Open Buildings	2.687.624
Microsoft Building Footprints original	1.537.635
Duplicados Microsoft-Google	764.492
Microsoft únicos agregados	773.143
Total final sin duplicados	3.460.767

5.3. Top 20 municipios por número de edificios — Google Open Buildings

Cuadro 6: Top 20 municipios PDET por número de edificios (Google, versión final)

#	Municipio	Edificios	Área Total (m ²)	Área Prom. (m ²)
1	SANTA MARTA	183,652	15,966,845.25	86.94
2	VALLEDUPAR	171,425	15,306,269.53	89.29
3	BUENAVENTURA	103,890	7,658,352.05	73.72
4	TURBO	78,927	6,036,411.11	76.48
5	FLORENCIA	58,135	7,334,010.74	126.15
6	SAN ANDRES DE TUMACO	50,493	3,793,315.73	75.13
7	TIERRALTA	43,123	3,078,702.71	71.39
8	CIENAGA	42,068	3,955,667.01	94.03
9	CAJIBIO	41,281	2,573,777.82	62.35
10	EL TAMBO	38,900	2,449,152.18	62.96
11	EL CARMEN DE BOLIVAR	38,386	2,541,160.53	66.20
12	APARTADO	36,337	3,599,828.36	99.07
13	TAME	35,958	3,183,325.12	88.53
14	SANTANDER DE QUILICHAO	35,691	3,842,935.10	107.67
15	ARAUQUITA	35,077	2,919,565.44	83.23
16	AGUSTIN CODAZZI	34,733	2,699,284.28	77.72
17	TIBU	32,843	2,636,703.11	80.28
18	SAN JOSE DEL GUAVIARE	32,695	3,147,419.35	96.27
19	NECOCLI	32,183	2,340,769.38	72.73
20	MORALES	31,057	1,965,301.82	63.28

5.4. Top 20 municipios por número de edificios — Microsoft Building Footprints

Cuadro 7: Top 20 municipios PDET por número de edificios (Microsoft, versión final)

#	Municipio	Edificios	Área Total (m ²)
1	SANTA MARTA	67,663	14,207,992.34
2	SAN ANDRES DE TUMACO	41,423	4,524,735.40
3	TIBU	35,478	3,569,509.95
4	EL TAMBO	34,366	3,051,941.00
5	BUENAVENTURA	33,020	7,138,217.08
6	SANTANDER DE QUILICHAO	30,841	4,234,663.51
7	TURBO	28,240	3,189,172.78
8	ARAUQUITA	27,815	3,317,209.87
9	FLORENCIA	26,896	6,683,829.91
10	EL CARMEN DE BOLIVAR	24,235	2,189,240.20
11	CAJIBIO	23,771	2,270,334.69
12	SAN VICENTE DEL CAGUAN	23,587	3,756,489.48
13	CIENAGA	21,990	3,473,952.89
14	SAN JOSE DEL GUAVIARE	21,446	3,099,880.81
15	PUERTO ASIS	21,234	3,056,417.43
16	TAME	20,958	2,761,029.83
17	MONTELIBANO	18,723	2,498,713.98
18	ORITO	17,840	2,029,245.49
19	SAN ONOFRE	17,348	1,490,877.96
20	CHAPARRAL	16,849	1,974,276.54

5.5. Análisis comparativo entre fuentes

Para los 168 municipios con cobertura en ambas fuentes, se calculó la diferencia en el número de edificios detectados y el ratio Google/Microsoft:

Cuadro 8: Comparativa de detecciones en municipios con cobertura en ambas fuentes (muestra top 10)

Municipio	Google	Microsoft	Diferencia	Ratio G/M
VALLEDUPAR	171,425	14,969	+156,456	11.45
SANTA MARTA	183,652	67,663	+115,989	2.71
BUENAVENTURA	103,890	33,020	+70,870	3.15
TURBO	78,927	28,240	+50,687	2.79
TIERRALTA	43,123	4,190	+38,933	10.29
APARTADO	36,337	2,652	+33,685	13.70
AGUSTIN CODAZZI	34,733	2,575	+32,158	13.49
FLORENCIA	58,135	26,896	+31,239	2.16
NECOCLI	32,183	10,119	+22,064	3.18
CIENAGA	42,068	21,990	+20,078	1.91

5.5.1. Hallazgos del análisis comparativo

- En **131 de los 168 municipios** comunes, Google detectó más edificios que Microsoft. La razón Google/Microsoft presenta una mediana cercana a **1.42x**.
- En municipios como **Valledupar** (ratio 11.45x) y **Tierralta** (ratio 10.29x), la diferencia es pronunciada, lo cual puede explicarse por diferencias en cobertura de imágenes, fechas de captura y criterios de detección entre fuentes.
- En **36 municipios**, Microsoft supera a Google (por ejemplo **Ataco**, **López** y **Rioblanco**), lo que evidencia que Microsoft aporta detecciones únicas en zonas donde Google presenta menor cobertura o mayor subdetección.
- La consolidación final no se basa en elegir una única fuente, sino en **deduplicar espacialmente** y conservar Google como fuente prioritaria, agregando únicamente huellas de Microsoft no solapadas significativamente.

5.6. Observaciones sobre calidad de datos

Cuadro 9: Comparación de atributos disponibles por fuente

Atributo	Google	Microsoft
Geometría (Polygon)	✓	✓
Área estimada (m ²)	✓	×
Nivel de confianza	✓	×
Altura del edificio	×	×
Código de ubicación (Plus Code)	✓	×
Municipios PDET analizados	170	170
Total edificios cargados	2,686,933	1,537,288

* Los campos height y confidence de Microsoft aparecen como -1 para Colombia.

6. Análisis Reproducible de Rooftops y Generación de Resultados

6.1. Objetivo del análisis

Con el fin de consolidar una metodología reproducible para el análisis del potencial solar en municipios PDET, se desarrolló el script:

02_rooftop_analysis.py

Este componente automatiza el cálculo de:

- Conteo total de edificaciones por municipio.
- Área total estimada de techos.
- Métricas de calidad espacial.
- Exportación geoespacial en formato GeoJSON.
- Generación automática de mapas temáticos.

El análisis se ejecuta directamente sobre las colecciones almacenadas en MongoDB, integrando los datasets de Google Open Buildings y Microsoft Building Footprints previamente cargados en el entorno NoSQL.

6.2. Ejecución reproducible

La ejecución del pipeline se diseñó bajo un enfoque reproducible mediante parámetros configurables desde línea de comandos:

```
1 python 02_rooftop_analysis.py \  
2 --mongo mongodb://localhost:27017/ \  
3 --out outputs
```

Listing 4: Ejecución del análisis reproducible

Los parámetros soportados por el script son:

Cuadro 10: Parámetros del análisis reproducible

Parámetro	Descripción
-mongo	URI de conexión hacia MongoDB
-db	Nombre de la base de datos utilizada
-out	Carpeta destino para exportación de resultados

6.3. Metodología implementada

El pipeline automatizado ejecuta las siguientes etapas metodológicas:

1. Carga de geometrías territoriales PDET desde MongoDB.
2. Carga de edificios Google y Microsoft.
3. Conversión de documentos GeoJSON a GeoDataFrames.
4. Validación geométrica de polígonos.

5. Cálculo de áreas en sistema métrico EPSG:9377.
6. Comparación espacial entre huellas de Google y Microsoft.
7. Identificación de duplicados mediante razón de solapamiento geométrico.
8. Consolidación final sin doble conteo, conservando Google como fuente prioritaria.
9. Agregación de conteos y áreas finales por municipio.
10. Exportación de tablas CSV, capas GeoJSON y mapas PNG.

6.4. Conversión y validación geoespacial

Para garantizar integridad espacial, cada documento almacenado en MongoDB fue convertido a objetos geométricos mediante Shapely:

```
1 geom = d.get('geom_field') or d.get("geometria")
2 g = shape(geom)
```

Listing 5: Conversión de geometrías GeoJSON

Durante el proceso se registraron métricas de calidad espacial:

- Documentos sin geometría.
- Geometrías inválidas.
- Geometrías correctamente cargadas.
- Edificios asignados espacialmente a municipios.

Estas métricas fueron posteriormente exportadas al archivo:

`quality_report.csv`

6.5. Cálculo de áreas de techos

Las áreas fueron calculadas utilizando el sistema de referencia métrico oficial:

`EPSG:9377`

Este CRS permite obtener superficies precisas en metros cuadrados para análisis de potencial solar.

```
1 gdf_metric = gdf.to_crs(epsg=9377)
2 geom_areas = gdf_metric.geometry.area.round(2)
```

Listing 6: Cálculo de áreas en CRS métrico

Cuando el dataset de Google ya contenía el atributo `area_estimada_m2`, el pipeline reutilizaba dicho valor para evitar reprocesamiento innecesario.

6.6. Cruce espacial y asignación municipal

La asignación territorial de los edificios se realizó previamente durante los scripts de carga, almacenando en cada documento el campo `codigo_mgn`. Posteriormente, el análisis reproducible utilizó este código para procesar municipio por municipio, reduciendo el costo computacional de las agregaciones.

La comparación entre Google y Microsoft se realizó en coordenadas proyectadas, utilizando el sistema EPSG:9377, con el fin de calcular correctamente áreas de intersección y áreas de techos en metros cuadrados.

```
1 overlap_ratio = area_interseccion / min(area_google, area_microsoft)
2
3 if overlap_ratio >= 0.50:
4     duplicado_google = True
5 else:
6     duplicado_google = False
```

Listing 7: Regla de deduplicación espacial

6.7. Agregación de resultados

Posteriormente se realizaron agregaciones estadísticas para calcular:

- Número total de edificios por municipio.
- Área total acumulada de techos.
- Resultados separados por fuente.
- Resultado consolidado sin duplicados entre Google y Microsoft.

$$\text{Total final sin duplicados} = \text{Google} + (\text{Microsoft} - \text{Duplicados Microsoft-Google})$$

En la ejecución final, esta fórmula produjo:

$$3,460,767 = 2,687,624 + (1,537,635 - 764,492)$$

```
1 df_municipio = df.groupby(
2     ["codigo_mgn", "nombre_municipio"]
3 ).agg(
4     total_edificios_sin_duplicados=("total_edificios_sin_duplicados", "sum"),
5     total_area_m2_sin_duplicados=("total_area_m2_sin_duplicados", "sum")
6 )
```

Listing 8: Agregación por municipio (resultado final)

6.8. Exportación de resultados

El pipeline exporta automáticamente múltiples salidas para análisis posteriores:

Cuadro 11: Archivos generados por el pipeline reproducible final

Archivo	Contenido
rooftop_by_municipio_fuente.csv	Conteos y áreas por municipio y fuente
rooftop_by_municipio_deduplicated.csv	Resultado final consolidado sin duplicados
quality_report.csv	Métricas de calidad espacial y duplicación
municipios_rooftop_deduplicated.geojson	Capa geoespacial municipal enriquecida con resultados finales
mapa_rooftop_count.png	Mapa de edificios sin duplicados por municipio
mapa_rooftop_area.png	Mapa de área total de techos sin duplicados por municipio
run_metadata.json	Metadatos metodológicos, versiones y resumen global

6.9. Generación automática de mapas

Como parte del análisis reproducible, el script genera automáticamente mapas coropléticos utilizando Matplotlib y GeoPandas.

```

1 gdf_mun.plot(
2     column="total_edificios_sin_duplicados",
3     ax=ax,
4     legend=True,
5     cmap="OrRd"
6 )

```

Listing 9: Generación automática de mapa temático




Figura 11: Mapa de edificios sin duplicados por municipio PDET. El resultado consolida Google Open Buildings y Microsoft Building Footprints evitando doble conteo por solapamiento espacial.




Figura 12: Mapa de área total de techos sin duplicados por municipio PDET, calculada en metros cuadrados mediante el sistema de referencia EPSG:9377.

6.10. Metadatos y reproducibilidad

Con el objetivo de asegurar trazabilidad y reproducibilidad científica, cada ejecución genera automáticamente un archivo:

`run_metadata.json`

Este archivo almacena:

- Fecha y hora UTC de ejecución.
- Parámetros utilizados.
- Versiones de librerías geospaciales.

- Número de geometrías procesadas.
- Metodología aplicada.

Un extracto del archivo generado se muestra a continuación:

```

1 {
2   "goal": "Estimate count and total rooftop area per PDET municipality.",
3   "area_calculation": "Areas calculated using projected CRS EPSG:9377.",
4   "deduplication": {
5     "threshold": 0.5,
6     "priority": "Google is kept as primary source; non-duplicate Microsoft
7       buildings are added."
8   },
9   "global_summary": {
10     "google_original_buildings": 2687624,
11     "microsoft_original_buildings": 1537635,
12     "microsoft_duplicates_with_google": 764492,
13     "microsoft_unique_added": 773143,
14     "final_buildings_without_duplicates": 3460767,
15     "total_rooftop_area_m2": 282191579.71
16   }
17 }
```

Listing 10: Metadatos de ejecución reproducible final

6.11. Resultados generales del análisis

La ejecución del pipeline permitió consolidar información geoespacial reproducible sobre el potencial de techos en municipios PDET.

Los principales resultados obtenidos incluyen:

- Procesamiento de **4.225.259** huellas de edificios provenientes de Google Open Buildings y Microsoft Building Footprints.
- Identificación de **764.492** huellas de Microsoft duplicadas con Google mediante solapamiento espacial.
- Consolidación de **3.460.767** edificios finales sin duplicados en los 170 municipios PDET.
- Estimación de **282.191.579,71 m²** de área total de techos sin duplicados (282,19 km²).
- Producción automática de capas geoespaciales y reportes reproducibles para análisis posterior.

Estos resultados constituyen la base para futuros análisis de potencial fotovoltaico y planeación energética territorial dentro del marco PDET. Estos resultados constituyen la base para futuros análisis de potencial fotovoltaico y planeación energética territorial dentro del marco PDET.

6.12. Hallazgos territoriales del análisis de rooftops

El análisis reproducible permitió identificar diferencias significativas en la distribución territorial de edificaciones dentro de los municipios PDET. A partir de los resultados agregados obtenidos en el archivo `rooftop_by_municipio_deduplicated.csv`, se consolidó el resultado oficial de la versión deduplicada, en la cual Google Open Buildings se conserva como fuente principal y Microsoft Building Footprints actúa como fuente complementaria. Las huellas de Microsoft con solapamiento significativo respecto a Google fueron excluidas del conteo final para evitar doble contabilización de techos.

El resultado consolidado comprende **3.460.767 edificios** distribuidos en los 170 municipios PDET, con un área total de techos de **282.191.579,71 m²** (282,19 km²), calculada geométricamente mediante

proyección al sistema de referencia métrico EPSG:9377. Cabe destacar que, dado que Microsoft Building Footprints no provee el atributo `area_in_meters` para Colombia —reportando valores de -1 en los campos `height` y `confidence`—, el área de sus huellas fue estimada directamente a partir de la geometría poligonal proyectada, manteniendo consistencia metodológica con el tratamiento aplicado al dataset de Google.

El Cuadro 12 presenta los 20 municipios con mayor número de edificios detectados en el resultado consolidado sin duplicados, mientras que el Cuadro 13 muestra los 20 municipios con mayor área total de techos.

Cuadro 12: Top 20 municipios PDET por cantidad de edificios — Resultado consolidado sin duplicados (Google + Microsoft)

#	Municipio	Edificios	Área total (m ²)	Área (ha)	Área (km ²)
1	Santa Marta	208.108	17.841.495,91	1.784,15	17,84
2	Valledupar	179.817	15.701.777,68	1.570,18	15,70
3	Buenaventura	118.398	8.928.950,99	892,90	8,93
4	Turbo	89.360	6.748.184,75	674,82	6,75
5	San Andrés de Tumaco	75.652	5.965.839,22	596,58	5,97
6	Florencia	66.892	7.941.304,45	794,13	7,94
7	El Tambo	62.008	4.062.485,54	406,25	4,06
8	Tibú	54.977	4.236.220,06	423,62	4,24
9	Santander de Quilichao	50.580	5.220.381,38	522,04	5,22
10	Araucuita	49.748	4.148.534,76	414,85	4,15
11	Ciénaga	49.248	4.443.834,55	444,38	4,44
12	Cajibío	47.590	2.940.102,91	294,01	2,94
13	Tame	47.543	4.199.296,54	419,93	4,20
14	El Carmen de Bolívar	45.809	2.923.709,67	292,37	2,92
15	Tierralta	45.262	3.209.412,14	320,94	3,21
16	San José del Guaviare	41.264	3.852.209,86	385,22	3,85
17	Puerto Asís	37.583	3.428.869,10	342,89	3,43
18	Apartadó	36.883	3.630.475,29	363,05	3,63
19	San Vicente del Caguán	36.855	4.468.540,10	446,85	4,47
20	Necoclí	36.850	2.602.735,74	260,27	2,60

Fuente: elaboración propia a partir de Google Open Buildings v3 y Microsoft Building Footprints.

Áreas calculadas en EPSG:9377. Deduplicación espacial con umbral IoU $\geq 0,50$.

Cuadro 13: Top 20 municipios PDET por área total de techos — Resultado consolidado sin duplicados (Google + Microsoft)

#	Municipio	Área total (m ²)	Área (ha)	Área (km ²)	Edificios
1	Santa Marta	17.841.495,91	1.784,15	17,84	208.108
2	Valledupar	15.701.777,68	1.570,18	15,70	179.817
3	Buenaventura	8.928.950,99	892,90	8,93	118.398
4	Florencia	7.941.304,45	794,13	7,94	66.892
5	Turbo	6.748.184,75	674,82	6,75	89.360
6	San Andrés de Tumaco	5.965.839,22	596,58	5,97	75.652
7	Santander de Quilichao	5.220.381,38	522,04	5,22	50.580
8	San Vicente del Caguán	4.468.540,10	446,85	4,47	36.855
9	Ciénaga	4.443.834,55	444,38	4,44	49.248
10	Tibú	4.236.220,06	423,62	4,24	54.977
11	Tame	4.199.296,54	419,93	4,20	47.543
12	Araucuita	4.148.534,76	414,85	4,15	49.748
13	El Tambo	4.062.485,54	406,25	4,06	62.008
14	San José del Guaviare	3.852.209,86	385,22	3,85	41.264
15	Apartadó	3.630.475,29	363,05	3,63	36.883
16	Puerto Asís	3.428.869,10	342,89	3,43	37.583
17	Tierralta	3.209.412,14	320,94	3,21	45.262
18	Montelíbano	3.140.424,82	314,04	3,14	36.211
19	Caucasia	2.973.872,32	297,39	2,97	33.540
20	Cajibío	2.940.102,91	294,01	2,94	47.590

Fuente: elaboración propia a partir de Google Open Buildings v3 y Microsoft Building Footprints.

Áreas calculadas en EPSG:9377. Deduplicación espacial con umbral IoU $\geq 0,50$.

Entre los principales hallazgos obtenidos se destacan:

- **Alta concentración de edificaciones en zonas urbanas consolidadas:** Santa Marta (208.108 edificios) y Valledupar (179.817 edificios) lideran el ranking consolidado, concentrando conjuntamente el 11,2 % del total de edificaciones detectadas en los 170 municipios PDET.
- **Divergencia entre cantidad y área:** Florencia ocupa el puesto 6 por número de edificios pero asciende al puesto 4 por área total de techos (7.941.304,45 m²), lo que sugiere una mayor proporción de construcciones de gran superficie, potencialmente industriales o institucionales, con alto potencial fotovoltaico por unidad de edificación.
- **Distribución desigual del área total de techos:** los dos primeros municipios por área (Santa Marta y Valledupar) concentran más de 33,5 km² de superficie de techos, equivalente al 11,9 % del área total estimada para el conjunto PDET.
- **Cobertura territorial heterogénea:** municipios ubicados en regiones selváticas del Pacífico y la Amazonía presentaron menores densidades de detección, coincidiendo con limitaciones de visibilidad satelital y dispersión poblacional características de estas zonas.
- **Mayor cobertura del dataset de Google:** Google Open Buildings detectó aproximadamente 1,75 veces más edificaciones que Microsoft en el conjunto procesado, aportando el 77,7 % del resultado final consolidado.
- **Consistencia espacial:** la tasa de asignación territorial mediante operaciones espaciales **within** confirmó alta coherencia entre las geometrías de edificios y los límites municipales PDET, con 164 geometrías válidas sobre 164 procesadas (tasa de error: 0 %).

El análisis de áreas acumuladas permite estimar que los 170 municipios PDET disponen de **282,19 km²** de superficie de techos potencialmente aprovechable para generación fotovoltaica distribuida. Municipios con alta concentración de edificaciones y condiciones favorables de radiación solar —como Santa Marta, Valledupar y Florencia— se convierten en candidatos estratégicos prioritarios para iniciativas de transición energética en el marco PDET.

Adicionalmente, el uso de métricas reproducibles y exportaciones geoespaciales en formatos abiertos (GeoJSON, CSV) facilita futuras etapas de modelamiento energético, simulación fotovoltaica y priorización territorial por parte de la UPME.

7. Comparación de Fuentes de Datos de Edificaciones

Con el fin de seleccionar la fuente más adecuada para la estimación del potencial solar en municipios PDET, se realizó una comparación conceptual y cuantitativa entre los conjuntos de datos Google Open Buildings y Microsoft Building Footprints, orientada al objetivo específico del proyecto: estimar el potencial solar en municipios PDET.

Google Open Buildings se caracteriza por ofrecer una cobertura amplia y uniforme obtenida mediante modelos de inteligencia artificial aplicados sobre imágenes satelitales. Esta fuente presenta alta disponibilidad en regiones en desarrollo y está diseñada para facilitar análisis a gran escala mediante formatos comprimidos optimizados para procesos masivos.

Por otra parte, Microsoft Building Footprints se enfoca en la detección precisa de huellas de edificaciones utilizando imágenes de alta resolución y modelos de visión computacional. En zonas donde sus datos están disponibles, suele entregar geometrías más detalladas y representaciones de forma más precisa de los edificios.

Para el caso específico de Colombia y de los territorios PDET, Google Open Buildings mostró una ventaja en cobertura territorial —en particular en áreas rurales—, lo que lo convierte en una fuente idónea para la identificación inicial de edificaciones a escala nacional. Microsoft Building Footprints, cuando está presente, aporta detecciones complementarias de mayor detalle geométrico que resultan útiles para validación y control de calidad.

La comparación numérica se resume en la siguiente tabla, construida a partir de los resultados consolidados del proyecto:

Cuadro 14: Comparación numérica entre Google Open Buildings y Microsoft Building Footprints

Métrica	Google	Microsoft
Edificios cargados	2.687.624	1.537.635
Edificios duplicados entre fuentes	–	764.492
Edificios únicos aportados al resultado final	2.687.624	773.143
Total consolidado sin duplicados		3.460.767

En términos de cobertura bruta, Google aportó aproximadamente 1.75 veces más edificaciones que Microsoft en el conjunto procesado. Sin embargo, Microsoft añadió más de 770 mil huellas únicas que enriquecen el resultado final y evidencian que ambas fuentes cumplen un rol complementario.

En consecuencia, la estrategia recomendada por este proyecto es:

Para interpretar mejor ese resultado, también conviene observar el peso relativo de cada fuente sobre el total procesado y sobre el resultado final consolidado:

Cuadro 15: Participación porcentual de cada fuente en el proceso

Métrica	Google	Microsoft
Participación sobre el total procesado (4.225.259 huellas)	63,6 %	36,4 %
Participación sobre el resultado final sin duplicados (3.460.767 edificios)	77,7 %	22,3 %

- Utilizar Google Open Buildings como fuente principal para estimaciones iniciales del potencial solar a escala nacional y para la identificación masiva de techos en municipios PDET.
- Emplear Microsoft Building Footprints como fuente complementaria de validación y para enri-

quecer la muestra en municipios donde sus detecciones estén disponibles.

- Mantener una política de deduplicación espacial (ver sección de metodología) en la que, ante solapamientos significativos, se priorice la geometría de Google para conservar continuidad en la base de referencia y se añadan huellas únicas de Microsoft.

8. Recomendaciones para la UPME

A partir del análisis geoespacial realizado sobre los 170 municipios PDET, se presentan las siguientes recomendaciones técnicas a la Unidad de Planeación Minero Energética (UPME):

1. **Priorizar Santa Marta, Valledupar y Florencia como municipios piloto para proyectos fotovoltaicos distribuidos.** Estos tres municipios concentran respectivamente 17,84 km², 15,70 km² y 7,94 km² de área total de techos, representando en conjunto el 14,7 % de los 282,19 km² estimados para el total de territorios PDET. Su alta densidad de edificaciones y consolidación urbana los convierten en los candidatos con mayor viabilidad técnica para una fase piloto de generación solar descentralizada.
2. **Adoptar Google Open Buildings como fuente base para identificación masiva de techos en territorios PDET.** En el análisis realizado, Google detectó 2.687.624 edificios frente a 1.537.635 de Microsoft, aportando el 77,7 % del resultado final consolidado de 3.460.767 edificios. Su cobertura es especialmente superior en municipios rurales y zonas de difícil acceso, donde Microsoft presentó subdetección significativa, como se evidenció en Valledupar (ratio Google/-Microsoft de 11,45x) y Tierralta (10,29x).
3. **Complementar el análisis con Microsoft Building Footprints para municipios con baja cobertura de Google.** En 36 de los 168 municipios con cobertura en ambas fuentes, Microsoft superó a Google en número de detecciones. Microsoft aportó 773.143 edificios únicos al resultado final, equivalentes al 22,3 % del consolidado. Ignorar esta fuente implicaría subestimar el potencial solar en municipios como Ataco, López y Rioblanco, donde Google presenta menor cobertura.
4. **Incorporar datos de radiación solar y demanda energética para una estimación precisa del potencial fotovoltaico.** Los 282,19 km² de área total de techos estimados representan la superficie máxima disponible, pero la superficie técnicamente aprovechable depende de factores como irradiación horizontal global (GHI), orientación e inclinación de techos, y demanda energética local. Se recomienda cruzar los resultados obtenidos con el Atlas de Radiación Solar del IDEAM para obtener estimaciones de generación en kWh por municipio.
5. **Mantener y escalar la infraestructura NoSQL geoespacial implementada.** La arquitectura MongoDB con índices `2dsphere` demostró capacidad para procesar 4.225.259 huellas de edificios distribuidas en 170 municipios, con inserción optimizada por lotes de 20.000 documentos e identificación de 764.492 duplicados mediante solapamiento espacial. Esta infraestructura es escalable al conjunto completo de municipios colombianos (1.122 según el MGN 2025) sin cambios arquitectónicos, lo que la convierte en una plataforma sostenible para futuras etapas del análisis energético territorial.

9. Conclusión

Este proyecto diseñó e implementó una arquitectura NoSQL geoespacial orientada al análisis del potencial solar en techos de edificaciones dentro de los territorios priorizados por los Programas de Desarrollo con Enfoque Territorial (PDET) en Colombia. A lo largo de cinco etapas —diseño del esquema, integración territorial, adquisición de datos, carga en MongoDB y análisis reproducible— se construyó un pipeline completo, documentado y reproducible que responde directamente al objetivo planteado por la UPME.

El resultado central del proyecto es la estimación de **3.460.767 edificios** y **282,19 km² de área total de techos** distribuidos en los **170 municipios PDET**, obtenida mediante la consolidación de-duplicada de Google Open Buildings (2.687.624 edificios) y Microsoft Building Footprints (1.537.635 edificios), con identificación y exclusión de 764.492 huellas duplicadas mediante una regla de solapamiento espacial con umbral $\text{IoU} \geq 0,50$.

La evaluación comparativa de fuentes evidenció que Google Open Buildings constituye la fuente más adecuada para caracterizaciones a escala nacional, aportando el 77,7 % del resultado final consolidado y mostrando cobertura superior en zonas rurales y de difícil acceso. Microsoft Building Footprints, por su parte, cumplió un rol complementario estratégico al agregar 773.143 edificios únicos no detectados por Google, enriqueciendo el análisis en municipios con subdetección de la fuente principal.

Desde el punto de vista metodológico, la decisión de calcular las áreas de techos de Microsoft geométricamente —mediante proyección al sistema de referencia EPSG:9377— garantizó consistencia en la estimación de superficies ante la ausencia del atributo `area_in_meters` en los archivos distribuidos para Colombia. Esta decisión, junto con la implementación de índices `2dsphere` y la escritura por lotes de 20.000 documentos, permitió procesar eficientemente más de 4,2 millones de huellas dentro de una arquitectura MongoDB escalable.

Los municipios de Santa Marta, Valledupar y Florencia se destacan como candidatos estratégicos prioritarios, concentrando conjuntamente más de 41,67 km² de área útil de techos. Estos resultados, exportados en formatos abiertos (GeoJSON, CSV) y acompañados de mapas coropléticos reproducibles, constituyen una base sólida para que la UPME avance hacia etapas de modelamiento fotovoltaico, simulación energética y priorización territorial en el marco de la transición energética colombiana.