

Proyecto Final

Diseño e Implementación de Arquitectura NoSQL Geoespacial para Análisis de Potencial Solar en Territorios PDET

Daniel González, Eduardo De Brigard, Juan Pablo Hernández

30 de mayo de 2026

1. Introducción

En el marco de la transición energética impulsada por la Unidad de Planeación Minero Energética (UPME), surge la necesidad de identificar zonas estratégicas para el despliegue de infraestructura de energía renovable en Colombia. Este proyecto se enfoca específicamente en evaluar el potencial de generación solar en los techos de edificaciones dentro de los territorios priorizados por los Programas de Desarrollo con Enfoque Territorial (PDET), buscando promover la equidad territorial y el desarrollo en regiones históricamente vulnerables. El principal desafío técnico radica en el procesamiento masivo de datos. Para estimar el área disponible para paneles solares, es necesario integrar y comparar datasets globales que contienen miles de millones de registros de huellas de edificios (como Google Open Buildings y Microsoft Building Footprints), junto con la delimitación administrativa del DANE. Dada la escala de la información y la naturaleza geográfica de los datos, este documento presenta una propuesta basada en tecnologías NoSQL, específicamente utilizando MongoDB. El uso de este paradigma permite una gestión flexible de esquemas y, sobre todo, una ejecución eficiente de operaciones espaciales complejas, fundamentales para cruzar los límites municipales con las estructuras detectadas por satélite.

2. Diseño del esquema de base de datos NoSQL y plan de implementación

2.1. Plan de Implementación

1. Preparación de la Infraestructura NoSQL

- Despliegue de MongoDB: Configuración de una instancia de base de datos orientada a documentos para el almacenamiento masivo de datos vectoriales.
- Indexación Espacial: Implementación de índices de tipo `2dsphere` para optimizar las consultas de proximidad y contención geográfica.

2. Adquisición e Integración de Datos Territoriales

- Filtro PDET: Procesamiento del Marco Geoestadístico Nacional (MGN) del DANE para extraer y limpiar los límites de los municipios priorizados como territorios PDET.
- Ingesta de Huellas de Edificios: Carga y normalización de al menos dos de los datasets globales (Microsoft Building Footprints y Google Open Buildings) en la base de datos NoSQL.
- Verificación de Integridad: Validación de formatos estructurales, topología de geometrías

y consistencia de códigos DIVIPOLA para asegurar la integridad referencial y la precisión espacial de los datos territoriales integrados en el esquema NoSQL.

3. Procesamiento y Análisis Geoespacial

- Intersección Espacial: Ejecución de operaciones de filtrado para identificar exclusivamente las estructuras ubicadas dentro de los polígonos municipales PDET.
- Cálculo de Áreas: Estimación de la superficie de los techos y conteo total de edificaciones por cada jurisdicción seleccionada.

4. Evaluación y Comparativa de Fuentes

- Auditoría de Datos (EDA): Realización de un análisis exploratorio para comparar la precisión y el volumen de detecciones entre los datasets seleccionados.
- Análisis de Discrepancias: Definición de métricas de validación para identificar variaciones en la detección de estructuras y determinar la fuente con mayor confiabilidad para el cálculo de áreas solares en los municipios seleccionados.

5. Consolidación de Resultados

- Generación de Reportes: Creación de visualizaciones cartográficas y tablas de resumen que identifiquen los municipios con mayor potencial para granjas solares.
- Documentación de Recomendaciones: Redacción de hallazgos técnicos alineados con los objetivos de transición energética y equidad territorial de la UPME.

2.2. Diseño del Modelo de Datos

2.2.1. A. Representación del Modelo (Estructura de Documentos)

A continuación, se presentan las colecciones principales definidas para el almacenamiento y procesamiento de información geoespacial dentro del entorno NoSQL propuesto.

Colección: territorios__pdet

- `_id`: Identificador único (ObjectId)
- `codigo_mgn`: Código municipal del DANE
- `nombre_municipio`: Nombre oficial
- `geometria_pdet`: Objeto GeoJSON (MultiPolygon) que define los límites del municipio
- `datos_pdet`: Información sobre el programa de desarrollo

Colección: huellas__edificios

- `_id`: Identificador único (ObjectId)
- `fuelle`: Origen del dato (Microsoft o Google)
- `geometria_edificio`: Objeto GeoJSON (Polygon) con la huella del edificio
- `area_estimada_m2`: Valor numérico calculado para el potencial solar
- `metadata`: Confianza de detección y fecha de captura




Figura 1: Esquema de base de datos

2.2.2. B. Instrumento de Modelado: Relación Espacial

En este modelo, la relación no se define mediante claves foráneas como en bases de datos relacionales, sino mediante una lógica de contención espacial:

- **Vínculo lógico:** Un documento en `huellas_edificios` pertenece a un territorio en `territorios_pdet` si su `geometria_edificio` está contenida dentro de `geometria_pdet`.
- **Mecanismo de consulta:** Se utilizará el operador `$geoWithin` de MongoDB para realizar el cruce de datos en tiempo de ejecución, evitando redundancia innecesaria.

2.3. Esquema de Datos y Justificación

Para cumplir con el requerimiento de una solución escalable y eficiente en operaciones espaciales, se ha diseñado un esquema basado en dos colecciones principales dentro de MongoDB.

2.3.1. Descripción de las Colecciones

Colección: `pdet_territories`

- **Propósito:** Almacenar los límites administrativos de los municipios designados como PDET, derivados del Marco Geoestadístico Nacional (MGN) del DANE.
- **Contenido:** Documentos que contienen el código municipal, nombre oficial y un campo `geometry` de tipo MultiPolygon bajo el estándar GeoJSON.
- **Índice:** Se implementará un índice `2dsphere` sobre el campo de geometría para permitir consultas de contención rápidas.

Colección: `building_footprints`

- **Propósito:** Consolidar las detecciones de edificios de los datasets de Google Open Buildings y Microsoft Building Footprints para su comparación.
- **Contenido:** Documentos con la huella del edificio (Polygon), el área calculada, la fuente del

dato y metadatos de confianza.

- **Optimización:** Se incluirá un campo con el código municipal (obtenido tras el procesamiento inicial) para facilitar agregaciones estadísticas sin necesidad de realizar cruces espaciales en cada consulta.

2.3.2. Justificación Técnica

La elección de este esquema y del motor NoSQL (MongoDB) se fundamenta en los siguientes pilares:

- **Soporte nativo geoespacial:** A diferencia de las bases de datos relacionales tradicionales, MongoDB maneja objetos GeoJSON de forma nativa. Esto facilita la ejecución de operadores como `$geoWithin` y `$geoIntersects`, esenciales para determinar qué edificios pertenecen a cada municipio PDET.
- **Escalabilidad:** El proyecto requiere procesar millones de registros provenientes de datasets globales de huellas de edificios. MongoDB permite manejar grandes volúmenes de información geoespacial de forma distribuida y eficiente.
- **Flexibilidad de esquema:** Debido a que los datasets utilizados provienen de múltiples fuentes (Google y Microsoft), existen diferencias estructurales y variaciones en atributos. El modelo orientado a documentos facilita la integración de estructuras heterogéneas sin requerir migraciones complejas.
- **Optimización de consultas espaciales:** La implementación de índices `2dsphere` permite acelerar operaciones de proximidad, intersección y contención espacial sobre polígonos territoriales y huellas de edificaciones.
- **Compatibilidad con pipelines geoespaciales:** El uso de GeoJSON facilita la interoperabilidad entre herramientas como QGIS, GeoPandas y MongoDB, permitiendo mantener consistencia espacial durante todas las etapas del procesamiento.

2.4. Integración de Datos Territoriales y Filtro PDET

En continuidad con el plan de implementación, se llevó a cabo la integración de la información geoespacial base para disponer de una colección preparada para análisis e ingesta en el entorno NoSQL.

2.4.1. Metodología de procesamiento y normalización

Para seleccionar los territorios priorizados se automatizó el cruce entre el Marco Geoestadístico Nacional (MGN) 2025 del DANE y el listado oficial de municipios PDET mediante scripts reproducibles en Python utilizando GeoPandas, Pandas y Matplotlib.

El flujo implementado permitió garantizar consistencia territorial, normalización de atributos y preparación geoespacial para posteriores procesos de ingesta en MongoDB.

Las acciones principales realizadas durante el procesamiento fueron:

- Estandarización de códigos DIVIPOLA.
- Limpieza de nombres territoriales.
- Eliminación de caracteres Unicode y tildes.
- Validación de coincidencias territoriales.
- Conversión geoespacial a formato GeoJSON.

Como insumo principal del proceso se utilizó la capa administrativa nacional correspondiente al archivo:

`MGN_ADM_MPIO_GRAFICO.shp`




Figura 2: Visualización del shapefile administrativo `MGN_ADM_MPIO_GRAFICO.shp` cargado en QGIS. La capa representa la totalidad de municipios contenidos en el Marco Geoestadístico Nacional (MGN 2025) del DANE.

Posteriormente, el script en Python realizó el filtrado territorial correspondiente a municipios priorizados PDET y generó el archivo geoespacial:

`pdet_final.geojson`




Figura 3: Visualización programática del archivo `pdet_final.geojson` generado mediante Python y GeoPandas. Cada color representa municipios PDET filtrados tras el proceso de integración territorial.

Las visualizaciones obtenidas permitieron realizar un proceso preliminar de validación espacial, verificando continuidad topológica y consistencia geométrica respecto al shapefile original del DANE.

2.4.2. Validación geoespacial y control de calidad

Con el objetivo de validar la integridad geométrica del dataset resultante, se realizaron pruebas visuales mediante QGIS y validaciones programáticas utilizando Python.

Las validaciones efectuadas incluyeron:

- Superposición correcta entre el shapefile original y el GeoJSON generado.
- Validación por lotes de geometrías municipales.
- Validación individual de polígonos territoriales.
- Verificación de continuidad espacial.
- Detección de posibles desplazamientos o geometrías corruptas.

Superposición de capas territoriales

La superposición entre capas permitió verificar que la transformación espacial no introdujera inconsistencias territoriales ni pérdida de entidades durante la conversión.




Figura 4: Superposición entre el shapefile original del DANE y el archivo `pdet_final.geojson`. La comparación permitió validar continuidad topológica y consistencia espacial entre ambas capas.

Validación visual mediante simbología

Adicionalmente, se realizaron pruebas manuales modificando simbologías y colores de capas dentro de QGIS con el fin de identificar posibles anomalías geométricas o desplazamientos espaciales.




Figura 5: Validación visual mediante modificación de simbología y colores en QGIS. Este procedimiento permitió identificar posibles inconsistencias geométricas y verificar independencia topológica entre polígonos municipales.

Validación por lotes

El proceso de control incluyó validaciones por lotes sobre múltiples geometrías municipales para verificar integridad estructural y correcta carga espacial.




Figura 6: Proceso de validación por lotes realizado sobre múltiples geometrías municipales. La validación confirmó una carga espacial exitosa y ausencia de errores topológicos críticos.

Validación individual de geometrías

También se realizaron inspecciones individuales sobre municipios específicos con el objetivo de corroborar la correcta representación cartográfica y creación adecuada de nuevas capas territoriales.




Figura 7: Validación individual de geometrías territoriales. La inspección permitió corroborar la correcta representación cartográfica de municipios específicos dentro del conjunto PDET.

Evidencia de ejecución del pipeline

Durante la ejecución del pipeline geoespacial se obtuvieron resultados de validación en consola similares a los siguientes:

Cruce por código DANE: encontrados 170 registros.

--- RESULTADOS ---

Municipios cargados del SHP: 1122

Municipios en tu lista PDET: 170

Municipios PDET encontrados tras el cruce: 170

[OK] Archivo 'pdet_final.geojson' creado correctamente.

Estos resultados evidencian la correcta integración territorial y la generación satisfactoria del dataset geoespacial requerido para etapas posteriores del proyecto.




Figura 8: Salida en consola del pipeline geoespacial implementado en Python, evidenciando la carga del shapefile, integración territorial y generación del archivo GeoJSON final.

Exportación geoespacial final

La exportación del subconjunto territorial resultante se realizó mediante la siguiente instrucción:

```
resultado_final.to_file(
    "pdet_final.geojson",
    driver="GeoJSON"
)
```

Esta transformación constituye una etapa crítica dentro del pipeline geoespacial, debido a que permite convertir estructuras territoriales tradicionales en objetos GeoJSON compatibles con MongoDB y operaciones espaciales NoSQL.

3. Adquisición de Datos

3.1. Google Open Buildings

3.1.1. Descripción del dataset

Google Open Buildings es un dataset desarrollado por Google Research que contiene detecciones de edificios derivadas de imágenes satelitales de alta resolución. La versión 3 del dataset cubre Lati-

noamérica, el Caribe, África, Asia del Sur y Asia del Sureste, con un área de inferencia de 58 millones de km².

Cuadro 1: Características del dataset Google Open Buildings

Atributo	Detalle
Versión	v3 (tercera versión)
Detecciones totales	~1.8 mil millones
Área de cobertura	58 millones de km ²
Formato de distribución	CSV comprimido (.csv.gz) por cuadrante
Atributos principales	geometry (WKT), area_in_meters, confidence, full_plus_code
Licencia	CC BY-4.0 / ODbL v1.0
URL	https://sites.research.google/gr/open-buildings/

3.1.2. Proceso de descarga

Los archivos fueron descargados directamente desde el portal de Google Open Buildings, filtrando por la región correspondiente a Colombia. Cada archivo CSV comprimido contiene las huellas de edificios para un cuadrante geográfico específico, con los siguientes campos principales:




Figura 9: Microsoft Building Footprints

Esto descarga unos archivos .csv.grz en los cuales estan los datos, en el script.py, se aplicó un filtro mínimo de confianza de **0.60** durante la carga, descartando detecciones con baja certeza de ser edificaciones reales.

3.2. Microsoft Global ML Building Footprints

3.2.1. Descripción del dataset

Microsoft Global ML Building Footprints es un dataset desarrollado por Microsoft Research a partir de imágenes de Bing Maps recolectadas entre 2014 y 2021, incorporando fuentes como Maxar y Airbus. Contiene más de 999 millones de detecciones de edificios a nivel mundial.

Cuadro 2: Características del dataset Microsoft Building Footprints

Atributo	Detalle
Detecciones totales	>999 millones
Período de imágenes	2014 – 2021
Formato de distribución	GeoJSON por cuadrante (QuadKey)
Atributos principales	geometry (GeoJSON Polygon), height, confidence
Licencia	Open Data Commons Open Database License (ODbL)
URL	https://planetarycomputer.microsoft.com/dataset/ms-buildings

3.2.2. Proceso de descarga

Microsoft distribuye sus datos a través de un índice CSV que lista todos los cuadrantes disponibles por país. El proceso de descarga se basó en el snippet oficial de Microsoft, adaptado para filtrar únicamente los cuadrantes correspondientes a Colombia, este proceso se descarga se puede ver en el pruebasDosMicro.py:

```
INDEX_URL = "https://mimedbuildings.z5.web.core.windows.net/global-buildings/dataset-links.csv"
LOCATION = "Colombia"
OUTPUT_FOLDER = "microsoft_geojson"

def main():
    log.info("=== Descarga Microsoft Buildings - Colombia ===")

    os.makedirs(OUTPUT_FOLDER, exist_ok=True)

    # --- 1. Descargar índice oficial de Microsoft ---
    log.info("Descargando índice de cuadrantes...")
    dataset_links = pd.read_csv(INDEX_URL)
    colombia_links = dataset_links[dataset_links.Location == LOCATION].reset_index(drop=True)
    log.info(f"Cuadrantes de {LOCATION}: {len(colombia_links)}")

    # --- 2. Descargar cada cuadrante ---
    ok = 0
    errores = 0

    for i, row in colombia_links.iterrows():
        quadkey = row.QuadKey
        url = row.Url
        destino = os.path.join(OUTPUT_FOLDER, f"{quadkey}.geojson")

        # Si ya existe, saltar
        if os.path.exists(destino):
            log.info(f" [{i+1}/{len(colombia_links)}] Ya existe: {quadkey}.geojson")
            ok += 1
            continue

        try:
            log.info(f" [{i+1}/{len(colombia_links)}] Descargando: {quadkey} ...")

            # Igual que el snippet oficial de Microsoft
            df = pd.read_json(url, lines=True)
            df["geometry"] = df["geometry"].apply(shape)
            gdf = gpd.GeoDataFrame(df, crs=4326)
            gdf.to_file(destino, driver="GeoJSON")

            log.info(f"    -> {len(gdf),} edificios guardados en {quadkey}.geojson")
            ok += 1
        except Exception as e:
            log.error(f"Error al descargar {quadkey}: {e}")
            errores += 1
```

Figura 10: Google open buildings

Para Colombia se identificaron y descargaron **229 cuadrantes GeoJSON**, cada uno correspondiente a un QuadKey único del sistema de indexación de Bing Maps.

4. Integración en MongoDB e Indexación Espacial

4.1. Arquitectura de colecciones

Los datos fueron almacenados en tres colecciones dentro de la base de datos proyecto en MongoDB:

Cuadro 3: Colecciones en MongoDB

Colección	Documentos	Propósito
territorios_pdet	170	Límites municipales PDET
google_buildings	2,686,933	Huellas de edificios (Google)
microsoft_buildings	1,537,288	Huellas de edificios (Microsoft)

4.2. Esquema de documento

Cada edificio, independientemente de la fuente, sigue el esquema unificado definido desde la semana 1:

```

1 {
2   "_id":           ObjectId,
3   "fuente":        "google" | "microsoft",
4   "codigo_mgn":    "47001",           // código DANE del municipio
5   "nombre_municipio": "SANTA MARTA",
6   "geometria_edificio": {             // GeoJSON Polygon
7     "type": "Polygon",
8     "coordinates": [[[lng, lat], ...]]
9   },
10  "area_estimada_m2": 87.39,           // solo Google
11  "metadata": {
12    "confianza":      0.78,
13    "altura_m":       null,           // solo Microsoft cuando disponible
14    "fuente_imagen":  "Google Satellite Imagery",
15    "dataset_version": "Google Open Buildings v3"
16  }
17 }
```

Listing 1: Esquema unificado de documento en mongodb

4.3. Indexación espacial

Se implementaron índices `2dsphere` sobre el campo `geometria_edificio` en ambas colecciones de edificios, junto con índices auxiliares para acelerar consultas por fuente y municipio:

```

1 # Índice geoespacial 2dsphere (requerido para geoWithin, geoIntersects)
2 col.create_index(
3   [("geometria_edificio", GEOSPHERE)],
4   name="idx_geo_edificio"
5 )
6 # Índices auxiliares para agregaciones
7 col.create_index("fuente", name="idx_fuente")
8 col.create_index("codigo_mgn", name="idx_codigo_mgn")
```

Listing 2: Creación de índices espaciales en MongoDB

4.4. Proceso de cruce espacial y filtro PDET

Un paso crítico en el pipeline de carga fue el cruce espacial entre cada edificio y los polígonos PDET. Solo se insertaron en MongoDB los edificios cuyo centroide cayera *dentro* de algún municipio PDET. Este filtro se implementó de dos formas según la fuente:

- **Google:** lectura por lotes de archivos CSV, conversión de geometrías WKT a objetos Shapely, uso de **STRtree** para consulta espacial eficiente y validación mediante el centroide de cada huella contra los polígonos PDET.
- **Microsoft:** lectura de archivos GeoJSON por cuadrante, reparación y validación de geometrías poligonales, asignación municipal mediante el centroide de cada edificio y limpieza posterior de geometrías incompatibles con índices **2dsphere**.

Aunque MongoDB permite ejecutar consultas espaciales mediante operadores como `$geoWithin` y `$geoIntersects`, en el pipeline final se decidió almacenar el campo `codigo_mgn` directamente en cada edificio durante la carga. Esta decisión reduce el costo de las agregaciones posteriores, ya que evita repetir cruces espaciales sobre millones de geometrías en cada consulta.

4.5. Eficiencia de carga

Para garantizar una carga eficiente de grandes volúmenes de datos, se implementó escritura por lotes con un tamaño de lote de 20,000 documentos. Además, los índices espaciales fueron creados al final de la carga para evitar que MongoDB actualizara los índices durante cada inserción masiva.

```

1 BATCH_SIZE = 20_000
2
3 batch.append(doc)
4
5 if len(batch) >= BATCH_SIZE:
6     col.insert_many(batch, ordered=False)
7     batch = []
8
9 if batch:
10    col.insert_many(batch, ordered=False)

```

Listing 3: Inserción por lotes optimizada

El parámetro `ordered=False` permite que MongoDB procese las inserciones en paralelo, mejorando el rendimiento y tolerando errores individuales sin detener el proceso completo.

5. Auditoría Inicial de Datos (EDA)

5.1. Resumen general

Tras completar la carga de ambos datasets, se realizó un análisis exploratorio de datos (EDA) directamente sobre las colecciones de MongoDB mediante pipelines de agregación. Los resultados globales se presentan a continuación:

Cuadro 4: Resumen general de edificios cargados y consolidación final

Métrica	Valor
Municipios PDET cargados	170
Edificios Google cargados	2,686,933
Edificios Microsoft cargados después de limpieza geométrica	1,537,288
Total de huellas procesadas en ambas fuentes	4,224,221
Duplicados Microsoft-Google detectados	764,327
Edificios Microsoft únicos agregados	772,961
Total final de edificios sin duplicados	3,459,894
Área total de techos sin duplicados (m ²)	282,081,655.68

Nota sobre Microsoft: el dataset de Microsoft no incluye el campo `area_in_meters` en sus GeoJSON de distribución. Los valores de `height` y `confidence` registrados en los archivos descargados para Colombia presentaron valores de -1, indicando que no estaban disponibles para esta región en particular.

Debido a la ausencia de un atributo de área directamente comparable en Microsoft, el área de techos para esta fuente fue calculada geométricamente a partir de las huellas proyectadas al sistema de referencia métrico EPSG:9377. Para mantener consistencia metodológica, el análisis final también calculó áreas geométricas sobre las huellas consolidadas.

5.2. Cobertura territorial comparativa

La cobertura territorial se evaluó sobre los **170 municipios PDET** cargados en la colección `territorios_pdet`. Para cada municipio se calcularon conteos separados por fuente y un resultado consolidado sin duplicados.

La estrategia final no consistió únicamente en sumar las detecciones de Google y Microsoft. En cambio, se compararon espacialmente las huellas de ambas fuentes para identificar posibles duplicados. Cuando una huella de Microsoft presentaba un solapamiento significativo con una huella de Google, se consideró duplicada y no se agregó al resultado final.

La regla de deduplicación utilizada fue:

$$\frac{\text{Área de intersección}}{\min(\text{Área Google}, \text{Área Microsoft})} \geq 0,50$$

Bajo esta regla, Google se conservó como fuente prioritaria y Microsoft se utilizó como fuente complementaria para agregar únicamente edificios no detectados por Google.

Cuadro 5: Consolidación entre fuentes después de deduplicación espacial

Categoría	Edificios
Google Open Buildings	2,686,933
Microsoft Building Footprints original	1,537,288
Duplicados Microsoft-Google	764,327
Microsoft únicos agregados	772,961
Total final sin duplicados	3,459,894

5.3. Top 20 municipios por número de edificios — Google Open Buildings

Cuadro 6: Top 20 municipios PDET por número de edificios (Google, versión final)

#	Municipio	Edificios	Área Total (m ²)	Área Prom. (m ²)
1	SANTA MARTA	183,652	15,966,845.25	86.94
2	VALLEDUPAR	171,425	15,306,269.53	89.29
3	BUENAVENTURA	103,890	7,658,352.05	73.72
4	TURBO	78,927	6,036,411.11	76.48
5	FLORENCIA	58,135	7,334,010.74	126.15
6	SAN ANDRES DE TUMACO	50,493	3,793,315.73	75.13
7	TIERRALTA	43,123	3,078,702.71	71.39
8	CIENAGA	42,068	3,955,667.01	94.03
9	CAJIBIO	41,281	2,573,777.82	62.35

#	Municipio	Edificios	Área Total (m ²)	Área Prom. (m ²)
10	EL TAMBO	38,900	2,449,152.18	62.96
11	EL CARMEN DE BOLIVAR	38,386	2,541,160.53	66.20
12	APARTADO	36,337	3,599,828.36	99.07
13	TAME	35,958	3,183,325.12	88.53
14	SANTANDER DE QUILCHAO	35,691	3,842,935.10	107.67
15	ARAUQUITA	35,077	2,919,565.44	83.23
16	AGUSTIN CODAZZI	34,733	2,699,284.28	77.72
17	TIBU	32,843	2,636,703.11	80.28
18	SAN JOSE DEL GUAVIARE	32,695	3,147,419.35	96.27
19	NECOCLI	32,183	2,340,769.38	72.73
20	MORALES	31,057	1,965,301.82	63.28

5.4. Top 20 municipios por número de edificios — Microsoft Building Footprints

Cuadro 7: Top 20 municipios PDET por número de edificios (Microsoft, versión final)

#	Municipio	Edificios	Área Total (m ²)
1	SANTA MARTA	67,663	14,207,992.34
2	SAN ANDRES DE TUMACO	41,423	4,524,735.40
3	TIBU	35,478	3,569,509.95
4	EL TAMBO	34,366	3,051,941.00
5	BUENAVENTURA	33,020	7,138,217.08
6	SANTANDER DE QUILCHAO	30,841	4,234,663.51
7	TURBO	28,240	3,189,172.78
8	ARAUQUITA	27,815	3,317,209.87
9	FLORENCIA	26,896	6,683,829.91
10	EL CARMEN DE BOLIVAR	24,235	2,189,240.20
11	CAJIBIO	23,771	2,270,334.69
12	SAN VICENTE DEL CAGUAN	23,587	3,756,489.48
13	CIENAGA	21,990	3,473,952.89
14	SAN JOSE DEL GUAVIARE	21,446	3,099,880.81
15	PUERTO ASIS	21,234	3,056,417.43
16	TAME	20,958	2,761,029.83
17	MONTELIBANO	18,723	2,498,713.98
18	ORITO	17,840	2,029,245.49
19	SAN ONOFRE	17,348	1,490,877.96
20	CHAPARRAL	16,849	1,974,276.54

5.5. Análisis comparativo entre fuentes

Para los 168 municipios con cobertura en ambas fuentes, se calculó la diferencia en el número de edificios detectados y el ratio Google/Microsoft:

Cuadro 8: Comparativa de detecciones en municipios con cobertura en ambas fuentes (muestra top 10)

Municipio	Google	Microsoft	Diferencia	Ratio G/M
VALLEDUPAR	171,425	14,969	+156,456	11.45
SANTA MARTA	183,652	67,663	+115,989	2.71
BUENAVENTURA	103,890	33,020	+70,870	3.15
TURBO	78,927	28,240	+50,687	2.79
TIERRALTA	43,123	4,190	+38,933	10.29
APARTADO	36,337	2,652	+33,685	13.70
AGUSTIN CODAZZI	34,733	2,575	+32,158	13.49
FLORENCIA	58,135	26,896	+31,239	2.16
NECOCLI	32,183	10,119	+22,064	3.18
CIENAGA	42,068	21,990	+20,078	1.91

5.5.1. Hallazgos del análisis comparativo

- En **131 de los 168 municipios** comunes, Google detectó más edificios que Microsoft. La razón Google/Microsoft presenta una mediana cercana a **1.42x**.
- En municipios como **Valledupar** (ratio 11.45x) y **Tierralta** (ratio 10.29x), la diferencia es pronunciada, lo cual puede explicarse por diferencias en cobertura de imágenes, fechas de captura y criterios de detección entre fuentes.
- En **36 municipios**, Microsoft supera a Google (por ejemplo **Ataco, López y Rioblanco**), lo que evidencia que Microsoft aporta detecciones únicas en zonas donde Google presenta menor cobertura o mayor subdetección.
- La consolidación final no se basa en elegir una única fuente, sino en **deduplicar espacialmente** y conservar Google como fuente prioritaria, agregando únicamente huellas de Microsoft no solapadas significativamente.

5.6. Observaciones sobre calidad de datos

Cuadro 9: Comparación de atributos disponibles por fuente

Atributo	Google	Microsoft
Geometría (Polygon)	✓	✓
Área estimada (m ²)	✓	×
Nivel de confianza	✓	×
Altura del edificio	×	×
Código de ubicación (Plus Code)	✓	×
Municipios PDET analizados	170	170
Total edificios cargados	2,686,933	1,537,288

* Los campos height y confidence de Microsoft aparecen como -1 para Colombia.

6. Análisis Reproducible de Rooftops y Generación de Resultados

6.1. Objetivo del análisis

Con el fin de consolidar una metodología reproducible para el análisis del potencial solar en municipios PDET, se desarrolló el script:

02_rooftop_analysis.py

Este componente automatiza el cálculo de:

- Conteo total de edificaciones por municipio.
- Área total estimada de techos.
- Métricas de calidad espacial.
- Exportación geoespacial en formato GeoJSON.
- Generación automática de mapas temáticos.

El análisis se ejecuta directamente sobre las colecciones almacenadas en MongoDB, integrando los datasets de Google Open Buildings y Microsoft Building Footprints previamente cargados en el entorno NoSQL.

6.2. Ejecución reproducible

La ejecución del pipeline se diseñó bajo un enfoque reproducible mediante parámetros configurables desde línea de comandos:

```
1 python 02_rooftop_analysis.py \  
2 --mongo mongodb://localhost:27017/ \  
3 --out outputs
```

Listing 4: Ejecución del análisis reproducible

Los parámetros soportados por el script son:

Cuadro 10: Parámetros del análisis reproducible

Parámetro	Descripción
-mongo	URI de conexión hacia MongoDB
-db	Nombre de la base de datos utilizada
-out	Carpeta destino para exportación de resultados

6.3. Metodología implementada

El pipeline automatizado ejecuta las siguientes etapas metodológicas:

1. Carga de geometrías territoriales PDET desde MongoDB.
2. Carga de edificios Google y Microsoft.
3. Conversión de documentos GeoJSON a GeoDataFrames.
4. Validación geométrica de polígonos.

5. Cálculo de áreas en sistema métrico EPSG:9377.
6. Comparación espacial entre huellas de Google y Microsoft.
7. Identificación de duplicados mediante razón de solapamiento geométrico.
8. Consolidación final sin doble conteo, conservando Google como fuente prioritaria.
9. Agregación de conteos y áreas finales por municipio.
10. Exportación de tablas CSV, capas GeoJSON y mapas PNG.

6.4. Conversión y validación geoespacial

Para garantizar integridad espacial, cada documento almacenado en MongoDB fue convertido a objetos geométricos mediante Shapely:

```
1 geom = d.get('geom_field') or d.get("geometria")
2 g = shape(geom)
```

Listing 5: Conversión de geometrías GeoJSON

Durante el proceso se registraron métricas de calidad espacial:

- Documentos sin geometría.
- Geometrías inválidas.
- Geometrías correctamente cargadas.
- Edificios asignados espacialmente a municipios.

Estas métricas fueron posteriormente exportadas al archivo:

`quality_report.csv`

6.5. Cálculo de áreas de techos

Las áreas fueron calculadas utilizando el sistema de referencia métrico oficial:

EPSG:9377

Este CRS permite obtener superficies precisas en metros cuadrados para análisis de potencial solar.

```
1 gdf_metric = gdf.to_crs(epsg=9377)
2 geom_areas = gdf_metric.geometry.area.round(2)
```

Listing 6: Cálculo de áreas en CRS métrico

Cuando el dataset de Google ya contenía el atributo `area_estimada_m2`, el pipeline reutilizaba dicho valor para evitar reprocesamiento innecesario.

6.6. Cruce espacial y asignación municipal

La asignación territorial de los edificios se realizó previamente durante los scripts de carga, almacenando en cada documento el campo `codigo_mgn`. Posteriormente, el análisis reproducible utilizó este código para procesar municipio por municipio, reduciendo el costo computacional de las agregaciones.

La comparación entre Google y Microsoft se realizó en coordenadas proyectadas, utilizando el sistema EPSG:9377, con el fin de calcular correctamente áreas de intersección y áreas de techos en metros cuadrados.

```
1 overlap_ratio = area_interseccion / min(area_google, area_microsoft)
2
3 if overlap_ratio >= 0.50:
4     duplicado_google = True
5 else:
6     duplicado_google = False
```

Listing 7: Regla de deduplicación espacial

6.7. Agregación de resultados

Posteriormente se realizaron agregaciones estadísticas para calcular:

- Número total de edificios por municipio.
- Área total acumulada de techos.
- Resultados separados por fuente.
- Resultado consolidado sin duplicados entre Google y Microsoft.

$$\text{Total final sin duplicados} = \text{Google} + (\text{Microsoft} - \text{Duplicados Microsoft-Google})$$

En la ejecución final, esta fórmula produjo:

$$3,459,894 = 2,686,933 + (1,537,288 - 764,327)$$

```
1 df_municipio = df.groupby(
2     ["codigo_mgn", "nombre_municipio"]
3 ).agg(
4     total_edificios_sin_duplicados=("total_edificios_sin_duplicados", "sum"),
5     total_area_m2_sin_duplicados=("total_area_m2_sin_duplicados", "sum")
6 )
```

Listing 8: Agregación por municipio (resultado final)

6.8. Exportación de resultados

El pipeline exporta automáticamente múltiples salidas para análisis posteriores:

Cuadro 11: Archivos generados por el pipeline reproducible final

Archivo	Contenido
rooftop_by_municipio_fuente.csv	Conteos y áreas por municipio y fuente
rooftop_by_municipio_deduplicated.csv	Resultado final consolidado sin duplicados
quality_report.csv	Métricas de calidad espacial y duplicación
municipios_rooftop_deduplicated.geojson	Capa geoespacial municipal enriquecida con resultados finales
mapa_rooftop_count.png	Mapa de edificios sin duplicados por municipio
mapa_rooftop_area.png	Mapa de área total de techos sin duplicados por municipio
run_metadata.json	Metadatos metodológicos, versiones y resumen global

6.9. Generación automática de mapas

Como parte del análisis reproducible, el script genera automáticamente mapas coropléticos utilizando Matplotlib y GeoPandas.

```

1 gdf_mun.plot(
2     column="total_edificios_sin_duplicados",
3     ax=ax,
4     legend=True,
5     cmap="OrRd"
6 )

```

Listing 9: Generación automática de mapa temático




Figura 11: Mapa de edificios sin duplicados por municipio PDET. El resultado consolida Google Open Buildings y Microsoft Building Footprints evitando doble conteo por solapamiento espacial.




Figura 12: Mapa de área total de techos sin duplicados por municipio PDET, calculada en metros cuadrados mediante el sistema de referencia EPSG:9377.

6.10. Metadatos y reproducibilidad

Con el objetivo de asegurar trazabilidad y reproducibilidad científica, cada ejecución genera automáticamente un archivo:

`run_metadata.json`

Este archivo almacena:

- Fecha y hora UTC de ejecución.
- Parámetros utilizados.
- Versiones de librerías geoespaciales.

- Número de geometrías procesadas.
- Metodología aplicada.

Un extracto del archivo generado se muestra a continuación:

```

1 {
2   "goal": "Estimate count and total rooftop area per PDET municipality.",
3   "area_calculation": "Areas calculated using projected CRS EPSG:9377.",
4   "deduplication": {
5     "threshold": 0.5,
6     "priority": "Google is kept as primary source; non-duplicate Microsoft
7       buildings are added."
8   },
9   "global_summary": {
10     "google_original_buildings": 2686933,
11     "microsoft_original_buildings": 1537288,
12     "microsoft_duplicates_with_google": 764327,
13     "final_buildings_without_duplicates": 3459894
14   }
15 }
```

Listing 10: Metadatos de ejecución reproducible final

6.11. Resultados generales del análisis

La ejecución del pipeline permitió consolidar información geoespacial reproducible sobre el potencial de techos en municipios PDET.

Los principales resultados obtenidos incluyen:

- Procesamiento de 4,224,221 huellas de edificios provenientes de Google Open Buildings y Microsoft Building Footprints.
- Identificación de 764,327 huellas de Microsoft duplicadas con Google mediante solapamiento espacial.
- Consolidación de 3,459,894 edificios finales sin duplicados en los 170 municipios PDET.
- Estimación de 282,081,655.68 m² de área total de techos sin duplicados.
- Producción automática de capas geoespaciales y reportes reproducibles para análisis posterior.

Estos resultados constituyen la base para futuros análisis de potencial fotovoltaico y planeación energética territorial dentro del marco PDET.

6.12. Hallazgos territoriales del análisis de rooftops

El análisis reproducible permitió identificar diferencias significativas en la distribución territorial de edificaciones dentro de los municipios PDET.

A partir de los resultados agregados obtenidos en:

rooftop_by_municipio_deduplicated.csv

El resultado oficial corresponde a la versión deduplicada del análisis. En esta versión, Google Open Buildings se conserva como fuente principal y Microsoft Building Footprints se utiliza como fuente complementaria. Las huellas de Microsoft que se solapan significativamente con Google son excluidas del conteo final para evitar doble contabilización de techos.

se evidenció que los municipios con mayor concentración de edificaciones corresponden principalmente a territorios con mayor densidad urbana y actividad económica regional.

Entre los principales hallazgos obtenidos se destacan:

- **Alta concentración de edificaciones en zonas urbanas consolidadas:** municipios como Santa Marta, Valledupar y Buenaventura presentaron los mayores conteos de edificaciones detectadas dentro de territorios PDET.
- **Distribución desigual del área total de techos:** aunque algunos municipios presentan menos edificaciones, el área promedio de techos es significativamente mayor, indicando presencia de construcciones de gran tamaño o baja densidad urbana.
- **Cobertura territorial heterogénea:** los municipios ubicados en regiones selváticas del Pacífico y Amazonía presentaron menores densidades de detección, lo cual coincide con limitaciones de visibilidad satelital y dispersión poblacional.
- **Mayor cobertura del dataset de Google:** Google Open Buildings logró detectar una cantidad considerablemente superior de edificaciones frente a Microsoft Building Footprints en la mayoría de municipios analizados.
- **Consistencia espacial:** la tasa de asignación territorial obtenida mediante operaciones espaciales *within* confirmó una alta coherencia entre las geometrías de edificios y los límites municipales PDET.

El análisis de áreas acumuladas permitió además estimar de manera preliminar el potencial de superficie disponible para futuras instalaciones fotovoltaicas distribuidas.

Los resultados muestran que municipios con alta concentración de edificaciones también presentan una elevada disponibilidad de área útil de techos, convirtiéndose en candidatos estratégicos para iniciativas de transición energética y generación solar descentralizada.

Adicionalmente, el uso de métricas reproducibles y exportaciones geoespaciales en formatos abiertos facilita futuras etapas de modelamiento energético, simulación fotovoltaica y priorización territorial por parte de entidades gubernamentales como la UPME.

7. Comparación de Fuentes de Datos de Edificaciones

Con el fin de seleccionar la fuente más adecuada para la estimación del potencial solar en municipios PDET, se realizó una comparación conceptual y cuantitativa entre los conjuntos de datos Google Open Buildings y Microsoft Building Footprints, orientada al objetivo específico del proyecto: estimar el potencial solar en municipios PDET.

Google Open Buildings se caracteriza por ofrecer una cobertura amplia y uniforme obtenida mediante modelos de inteligencia artificial aplicados sobre imágenes satelitales. Esta fuente presenta alta disponibilidad en regiones en desarrollo y está diseñada para facilitar análisis a gran escala mediante formatos comprimidos optimizados para procesos masivos.

Por otra parte, Microsoft Building Footprints se enfoca en la detección precisa de huellas de edificaciones utilizando imágenes de alta resolución y modelos de visión computacional. En zonas donde sus datos están disponibles, suele entregar geometrías más detalladas y representaciones de forma más precisa de los edificios.

Para el caso específico de Colombia y de los territorios PDET, Google Open Buildings mostró una ventaja en cobertura territorial —en particular en áreas rurales—, lo que lo convierte en una fuente idónea para la identificación inicial de edificaciones a escala nacional. Microsoft Building Footprints, cuando está presente, aporta detecciones complementarias de mayor detalle geométrico que resultan útiles para validación y control de calidad.

La comparación numérica se resume en la siguiente tabla, construida a partir de los resultados consolidados del proyecto:

Cuadro 12: Comparación numérica entre Google Open Buildings y Microsoft Building Footprints

Métrica	Google	Microsoft
Edificios cargados	2,686,933	1,537,288
Edificios duplicados entre fuentes	–	764,327
Edificios únicos aportados al resultado final	2,686,933	772,961
Total consolidado sin duplicados		3,459,894

En términos de cobertura bruta, Google aportó aproximadamente 1.75 veces más edificaciones que Microsoft en el conjunto procesado. Sin embargo, Microsoft añadió más de 770 mil huellas únicas que enriquecen el resultado final y evidencian que ambas fuentes cumplen un rol complementario.

En consecuencia, la estrategia recomendada por este proyecto es:

Para interpretar mejor ese resultado, también conviene observar el peso relativo de cada fuente sobre el total procesado y sobre el resultado final consolidado:

Cuadro 13: Participación porcentual de cada fuente en el proceso

Métrica	Google	Microsoft
Participación sobre el total procesado	63.6 %	36.4 %
Participación sobre el resultado final sin duplicados	77.7 %	22.3 %

- Utilizar Google Open Buildings como fuente principal para estimaciones iniciales del potencial solar a escala nacional y para la identificación masiva de techos en municipios PDET.
- Emplear Microsoft Building Footprints como fuente complementaria de validación y para enriquecer la muestra en municipios donde sus detecciones estén disponibles.

- Mantener una política de deduplicación espacial (ver sección de metodología) en la que, ante solapamientos significativos, se priorice la geometría de Google para conservar continuidad en la base de referencia y se añadan huellas únicas de Microsoft.

8. Recomendaciones para la UPME

A partir del análisis realizado y de la arquitectura geoespacial propuesta, se recomienda a la Unidad de Planeación Minero Energética (UPME):

- Utilizar Google Open Buildings como fuente base para la identificación inicial de edificaciones dentro de municipios PDET debido a su amplia cobertura territorial.
- Complementar el análisis mediante muestras de validación utilizando Microsoft Building Footprints cuando exista disponibilidad de datos para la misma región.
- Integrar información de radiación solar, cobertura eléctrica y demanda energética para obtener estimaciones más precisas del potencial fotovoltaico a nivel municipal.
- Mantener una infraestructura orientada a documentos (MongoDB) y formatos GeoJSON para facilitar futuras ampliaciones del sistema y permitir consultas espaciales eficientes sobre grandes volúmenes de información.
- Priorizar municipios PDET con alta concentración de edificaciones y condiciones favorables de radiación solar para maximizar el impacto de futuras inversiones en generación distribuida.

9. Conclusión

El proyecto diseñó e implementó una arquitectura NoSQL orientada al almacenamiento y procesamiento de información geoespacial para el análisis de potencial solar en territorios PDET. Mediante la integración del Marco Geoestadístico Nacional (MGN) y la generación de conjuntos de datos compatibles con MongoDB, se estableció una base sólida para realizar análisis espaciales a gran escala.

La evaluación comparativa de las fuentes de datos indicó que Google Open Buildings constituye una alternativa adecuada para la caracterización inicial de edificaciones en municipios priorizados, gracias a su amplia cobertura territorial y disponibilidad en zonas rurales. Microsoft Building Footprints desempeña un rol complementario valioso como mecanismo de validación y control de calidad en las áreas donde está disponible.

La solución propuesta proporciona una infraestructura escalable y reproducible que permite incorporar etapas posteriores de análisis, incluyendo la estimación de superficies útiles para la instalación de paneles solares, la generación de métricas energéticas y la priorización de territorios para la transición energética en Colombia.

En este sentido, el trabajo desarrollado constituye una herramienta de apoyo para la toma de decisiones de la UPME y demuestra el potencial de las tecnologías NoSQL para abordar problemas de análisis geoespacial asociados al desarrollo sostenible y la planificación energética nacional.